Diagnósticos certificados de los límites de velocidad cuánticos en procesadores superconductores en uso

Carles Marín

***Resumen*—¿Hasta qué punto están las puertas cuánticas en uso cerca de la evolución más rápida que permite la mecánica cuántica? Respondemos para los procesadores IBM anteriores a Heron, sobre todo Falcon y Eagle, a partir de instantáneas de calibración públicas y con versión fijada, y de desigualdades cuyas demostraciones están verificadas por máquina en Lean 4. Las instantáneas de Heron carecen de hamiltoniano. Para las puertas de un cúbit, con el convenio de intensidad de excitación fijado por los pulsos π calibrados de IBM, la puerta X dura una mediana de 11.3 veces el límite de velocidad de dos niveles a plena amplitud de excitación (1646 cúbits, 41 backends). La mayor parte de esta distancia es una decisión de diseño: IBM excita a aproximadamente una décima parte de la anarmonicidad y, con esa excitación, sus pulsos duran unas 2 veces el límite del pulso cuadrado. Dentro de la amplitud máxima de cada dispositivo, el control óptimo sobre el modelo de IBM da puertas unas 10 veces más rápidas que la mediana. Para las puertas de dos cúbits (1758 pares acoplados, 43 backends), el tiempo mínimo conocido, en el subespacio de cúbits, de las puertas de clase controlled-NOT con acoplamiento de intercambio (literatura) da una razón mediana de 4.22; a lo largo de las instantáneas, la razón subió, de forma no monótona, de 2.78 (2021) a 4.26 (2025) a medida que las puertas se alargaban, coincidiendo con el paso de Falcon a Eagle. Con el segundo nivel y un control local arbitrario y rápido, el tiempo mínimo de una puerta controlled-Z con control local ideal está entre 0.295 y 0.331 del tiempo de intercambio con solo cúbits (una cota con dos copias y un protocolo explícito certificado, versión 3); un control local acotado alcanza 0.35. Formalizamos además una cota del tiempo de entrelazamiento en dimensión local arbitraria, conocida para cúbits y nueva solo como ensamblaje verificado por máquina. Aplicado a la transferencia de estado entre chips de IBM (versión 2), el mismo diagnóstico sitúa las transferencias en 5.8–7.9 veces el tiempo mínimo de un solo modo, cuya cota inferior está verificada por máquina en Isabelle, y el error de coherencia del protocolo más rápido entre cuatro y seis veces por debajo de los errores medidos. La contribución es un diagnóstico reproducible construido sobre las desigualdades verificadas por máquina, con garantías explícitas.**

***Palabras clave*—Límite de velocidad cuántico, cúbits superconductores, transmón, tiempo de puerta, resonancia cruzada, Mandelstam–Tamm, Margolus–Levitin, tiempo de entrelazamiento, verificación formal, Lean, cálculo reproducible.**

Sitio complementario. https://karlesmarin.github.io/blueprints/qsl-diagnostics/: cada afirmación de este artículo con su teorema de Lean o su script, los programas y los datos, y laboratorios en el navegador que rehacen las Figs. 1–4 y diagnostican las puertas del propio lector (Sección X). Este preprint: doi:10.5281/zenodo.23783382.

I. Introducción

C. Marín es investigador independiente (correo electrónico: karlesmarin@gmail.com).

La duración de las puertas interviene en todas las cifras de mérito de un procesador cuántico: determina cuántas operaciones caben en el tiempo de coherencia y se compensa con la fuga y el error de control. Los límites de velocidad cuánticos (QSL, por sus siglas en inglés)—Mandelstam–Tamm (MT) [1], Margolus–Levitin (ML) [2] y su familia de momentos fraccionarios, debida a Zieliński y Zych [3]—acotan la rapidez con que un estado puede evolucionar hasta otro ortogonal (o parcialmente distinguible), dada una escala de energía. Para las puertas de dos cúbits, el objeto análogo es el tiempo mínimo de interacción con control local rápido [4], [5], [6].

Un diagnóstico natural es entonces la *distancia*: la duración calibrada de la puerta dividida por el límite de velocidad que implican los parámetros hamiltonianos del propio dispositivo. Dos cosas hacen delicado este diagnóstico. La primera es que la escala de energía debe ser la adecuada: con el hamiltoniano de laboratorio de un transmón, la cota MT/ML mide la frecuencia portadora y es vacía (~ 0.1 ns frente a tiempos de puerta de decenas o cientos de ns); las escalas con sentido son la amplitud de excitación en el sistema rotante (un cúbit) y el acoplamiento (dos cúbits). La segunda es que los convenios de los datos del fabricante (factores de 2 y 2π, qué parámetro se mide y cuál se deriva) deben fijarse con datos independientes, o el diagnóstico informa del convenio y no del dispositivo.

Este artículo aporta cinco cosas.

(1) Cotas certificadas. Las desigualdades de la Tabla I están demostradas en Lean 4 en el desarrollo público [25] (la cota de puerta de dos cúbits $\pi/(2j_q)$ que sustenta el 4.22 de la cifra principal se toma de la literatura y no está entre ellas): Margolus–Levitin, una forma L^1 de Mandelstam–Tamm, la familia de Zieliński–Zych para todo exponente $\alpha > 0$ (cuya desigualdad auxiliar clave el artículo original enuncia sin demostración), una cota para un cúbit dependiente del tiempo con su caso de igualdad para pulsos de eje fijo y su versión con tolerancia finita, una cota del tiempo de entrelazamiento en dimensión local arbitraria con sus versiones desplazada, localmente equivalente (ECR) y con tolerancia finita (Sección II) y, para la CZ en transmones de d niveles, las cotas de norma que sustentan su ajuste asintótico y el lema clave de la cota refinada (Sección VII).

(2) Un convenio fijado con datos independientes. El parámetro de intensidad de excitación queda fijado por los pulsos π calibrados de IBM mediante una identidad exacta de área del pulso que se cumple en los 777 cúbits con definiciones de pulso, salvo por cuál de las dos normalizaciones del pulso llega

al cúbit, lo que además revela que se deriva de la calibración y no se mide de forma independiente (Sección III).

(3) Un barrido del hardware en uso: puertas de un cúbit en 1646 cúbits, puertas de dos cúbits en 1758 pares y una serie temporal 2021–2025 (Secciones IV–VI); para el barrido de un cúbit se escribieron un falsador y tres hipótesis rivales antes del análisis, y damos cuenta de su suerte.

(4) Tiempos factibles hallados por control óptimo sobre el modelo del propio fabricante, acotados por cotas inferiores (certificadas o demostradas en el texto) y, para la CZ, por una construcción explícita que, en transmones de d niveles, se aproxima a la cota del tiempo de entrelazamiento cuando $d \to \infty$ con norma de interacción fija y control local ideal (Sección VII).

(5) Una aplicación más allá de las puertas (versión 2): la transferencia de estado entre chips de IBM [21] dura 5.8–7.9 veces el tiempo mínimo de un solo modo, cuya cota inferior verificamos por máquina en Isabelle; la ecuación maestra del protocolo óptimo sitúa su error de coherencia entre cuatro y seis veces por debajo de los errores medidos (Sección VIII).

Trabajo previo más cercano. Ishida y Hasegawa [12] aplican los límites de velocidad en sentido inverso al procesador Heron `ibm_torino`: miden la duración de las puertas a partir del tiempo de reloj de los trabajos mediante amplificación del tiempo de puerta (X: 32 ns, CZ: 70 ns) e infieren cotas inferiores independientes del modelo para las escalas de energía—mediante MT, sobre la dispersión de energía promediada en el tiempo, y mediante ML, sobre un hamiltoniano efectivo independiente del tiempo—, las encuentran del orden de las energías de excitación típicas y concluyen que las puertas operan cerca del límite de velocidad. Para una rotación π de eje fijo $H(t) = f(t)\sigma_x/2$ con $f \geq 0$ a partir de $|0\rangle$ se tiene $\langle H\rangle = 0$ y $\Delta E(t) = f(t)/2$, y el estimador MT es exactamente igual al promedio temporal de ΔE, sea cual sea la forma del pulso (Sección II): la razón entre la duración y ese límite vale 1 por construcción, de modo que el estimador fija una escala de energía y no una distancia. (Aquí la energía es la dispersión del hamiltoniano de excitación en el sistema rotante, no la energía entregada por la electrónica de control.) Nosotros tomamos en cambio la escala del hamiltoniano calibrado (amplitud máxima de excitación, acoplamiento de intercambio) y damos razones duración/límite. Las dos visiones son numéricamente compatibles una vez que se indican los denominadores: con la excitación que IBM usa realmente, la puerta X está a un factor 2 aproximadamente del límite del pulso cuadrado (forma del pulso y normalización del pulso) y unas 11 veces por encima del límite a plena amplitud de excitación (Sección IV-C). Su medida no necesita modelo y cubre un dispositivo Heron actual; nuestro diagnóstico necesita el hamiltoniano del fabricante, así que cubre solo instantáneas anteriores a Heron (sobre todo Falcon y Eagle), pero abarca 41 backends y 2021–2025 y se apoya en desigualdades verificadas por máquina.

No afirmamos física nueva: los límites de velocidad son clásicos, las constantes de dos cúbits son conocidas para cúbits y el modelo del transmón es el de IBM. Las excepciones son matemáticas: el código de cuadraturas de d niveles para la CZ y su ajuste asintótico no se encontraron en las fuentes que leímos (Sección VII). Hasta donde sabemos, ningún trabajo previo aplica un QSL certificado por un asistente de pruebas a datos públicos de calibración con una distancia por puerta; una búsqueda que no encuentra nada no demuestra novedad. La Sección IX indica qué cubre el certificado.

II. Cotas certificadas

Las unidades son $\hbar = 1$. Los enunciados de los elementos de las listas, el Teorema y los corolarios siguientes son teoremas del desarrollo en Lean 4 [25]; las observaciones y comprobaciones numéricas no lo son (módulo `Formalizations/Physics/QuantumMechanics/SpeedLimit`, commit `42f307b`); la Tabla I recoge los nombres de los teoremas y el estado de cada enunciado en la literatura.

II-A. Límites de velocidad de un solo sistema

Sea un estado con poblaciones $p_n \geq 0$, $\sum_n p_n = 1$, sobre energías E_n, y autocorrelación $S(\tau) = \sum_n p_n e^{-iE_n\tau}$. Si $S(\tau) = 0$ (ortogonalidad) en $\tau \geq 0$:

- *Margolus–Levitin* (`QSL.margolus_levitin`): con $E_n \geq 0$, $\pi \leq 2\langle E\rangle\tau$.
- *Mandelstam–Tamm, forma* L^1 (`QSL.mandelstam_tamm_L1`): $1 \leq D_1\tau$ con $D_1 = \sum_n p_n|E_n - \bar{E}|$; con `QSL.mandelstam_tamm_weak`, $1 \leq \Delta E\,\tau$. La constante completa de MT, $\tau \geq \pi/(2\Delta E)$, *no* está demostrada en el desarrollo.
- *Zieliński–Zych* (`QSL.zielinski_zych_all`, `QSL.zielinski_zych_time_all`): con $E_n \geq E_0$ en los niveles poblados y $M_\alpha = \sum_n p_n(E_n - E_0)^\alpha$, $\pi^\alpha \leq 2M_\alpha\tau^\alpha$ para todo $\alpha > 0$. La desigualdad auxiliar $x^\alpha - \pi^\alpha/2 + (\pi^\alpha/2)\cos x + \alpha\pi^{\alpha-1}\sin x \geq 0$ ($x \geq 0$) se enuncia sin demostración en [3] para todo $\alpha > 0$; Lean la demuestra para $0 < \alpha \leq 1$ (`QSL.zz_inequality`) y para $\alpha \geq 1$ (`QSL.zz_inequality_of_one_le`).

Para un sistema de dos niveles excitado con frecuencia de Rabi constante Ω, ML da $\tau \geq \pi/\Omega$ para $|0\rangle \to |1\rangle$, saturada por un pulso π cuadrado. Este es el tiempo de referencia de un cúbit que se usa en la Sección IV. Para una excitación *dependiente del tiempo*, que es lo que necesita un pulso con forma, se certifican dos enunciados más. (i) Toda evolución constante a trozos cuyos hamiltonianos cumplan $\|H_k - c_k\mathbb{1}\| \leq \Omega_{\text{máx}}/2$ para ciertos c_k reales (anchura espectral como máximo $\Omega_{\text{máx}}$; para $H = (\Omega/2)\,\hat{n}\cdot\vec{\sigma}$ esto es $|\Omega| \leq \Omega_{\text{máx}}$) mueve cualquier estado un ángulo de Fubini–Study de como máximo $(\Omega_{\text{máx}}/2)\,T$ (`QSL.Gate.fsAngle_le_time_halfWidth`); por tanto, $|0\rangle \to |1\rangle$ requiere $T \geq \pi/\Omega_{\text{máx}}$ para toda forma de pulso. (ii) Para una excitación de eje fijo $H(t) = f(t)\,\sigma_x/2$ con $f \geq 0$ y $\int f \leq \pi$, partiendo de $|0\rangle$ (un estado ortogonal al eje en la esfera de Bloch), la cota generalizada de MT $\int \Delta E\,dt \geq \arccos|\langle\psi_0|\psi_T\rangle|$ se cumple con *igualdad*, habiéndose demostrado que la trayectoria resuelve la ecuación de Schrödinger (`QSL.FixedAxis.mandelstam_tamm_integral_eq_solution`): todo pulso π de eje fijo tiene una razón al límite de velocidad exactamente igual a 1, sea cual sea su forma. Esta es la identidad que está detrás de las razones cercanas a la unidad que se notifican para pulsos π

en [12]. No se extiende a los pulsos DRAG, cuya cuadratura hace que el eje dependa del tiempo (pruébelo en la esfera de Bloch con cualquier envolvente, un término DRAG o una desintonía).

II-B. Tiempo de entrelazamiento en dimensión local arbitraria

Dos sistemas con tipos de índices finitos (dimensiones locales arbitrarias, ancillas incluidas) evolucionan bajo $\prod_k \exp[-i\tau_k(A_k \otimes 1 + 1 \otimes B_k + H)]$, con A_k, B_k hermíticos y no acotados (control local constante a trozos), $\tau_k \geq 0$, y una interacción hermítica constante H con $\|H\| \leq J$ (norma de operador). En esta sección J es siempre una cota de esa norma; en las Secciones V y VII el *coeficiente* de intercambio se escribe j_q o J y la norma correspondiente se indica en cada caso (es J con dos niveles y $2J$ con tres).

Teorema (`QSL.Qudit.arccos_le_entangling_time`). Si la evolución lleva un vector producto unitario a Φ, y todo vector producto unitario tiene un solapamiento de como máximo λ con Φ, entonces $\arccos\lambda \leq J\sum_k \tau_k$.

El solapamiento de un estado con los vectores producto está acotado por su mayor coeficiente de Schmidt. Para un vector de Bell de dos niveles $(e_{00} + e_{11})/\sqrt{2}$ dentro de qudits de cualquier dimensión $d \geq 2$, $\lambda = 1/\sqrt{2}$, de modo que $J\sum_k \tau_k \geq \pi/4$ (`QSL.Qudit.pi_div_four_le_entangling_time_fin`). La cota se alcanza: $H = J\,Z \otimes X$ lleva un vector producto al vector de Bell en un solo paso de duración $\pi/(4J)$ (`QSL.Qudit.entangling_time_tight`). La demostración es una estimación de Duhamel en el ángulo de Fubini–Study encadenada a lo largo de los pasos de control. Una versión anterior con distancia de cuerda en el mismo desarrollo (`QSL.TwoQubit.entangling_time_lower_bound`) da la constante más débil $\sqrt{2-\sqrt{2}} \approx 0.7654$, un $2.6\,\%$ por debajo del tiempo de acoplamiento de intercambio $\pi/(4J) = 0.7854/J$.

Consecuencia para la CNOT. La CNOT lleva $|+\rangle|0\rangle$ al estado de Bell, de modo que toda implementación de la CNOT en el subespacio de cúbits de dos sistemas de d niveles necesita $JT \geq \pi/4$, con J la norma de la interacción en el espacio *completo* de d niveles. Una comprobación numérica independiente (`cnot_m3.py`) de la constante de solapamiento pertinente da $m_d = 0.707107$ ($d = 2$) y 0.707105 ($d = 3$) para el mayor solapamiento de una salida de la CNOT con vectores producto, sobre 45 inicios, coherente con $1/\sqrt{2}$; una maximización a partir de un número finito de inicios es una comprobación, no un certificado. Lo mismo vale para toda puerta solo *localmente equivalente* a la CNOT, como la resonancia cruzada con eco (ECR) de IBM: una puerta así lleva algún vector producto a $(P \otimes Q)$ aplicado a un vector de Bell, los unitarios locales no cambian el solapamiento con los vectores producto y, por tanto, $JT \geq \pi/4$ (`QSL.Qudit.pi_div_four_le_entangling_time_local`; con un acoplamiento desplazado, `..._shift_local`).

Dos corolarios más. (a) Un múltiplo de la identidad en H puede absorberse en el control local, de modo que $\|H\|$ puede sustituirse por $\|H - c\mathbb{1}\|$ para cualquier c real, es decir, por la semianchura espectral (`QSL.Qudit.arccos_le_entangling_time_shift`); para el acoplamiento de Heisenberg $XX + YY + ZZ$ esto da 2 en lugar de 3 y el tiempo de Bell $\pi/8$ (`QSL.Qudit.pi_div_eight_le_heisenberg_time`). (b) Si el estado final solo tiene fidelidad $1 - \varepsilon$ con el vector de Bell, la desigualdad triangular del ángulo de Fubini–Study da $J\sum_k \tau_k \geq \pi/4 - \arcsin\sqrt{\varepsilon}$ (`QSL.Qudit.pi_div_four_sub_le_entangling_time_approx`); asimismo, una transferencia de dos niveles con fidelidad $1 - \varepsilon$ necesita $\Omega_{\max} T \geq 2\arccos\sqrt{\varepsilon}$ (`QSL.Gate.two_arccos_sqrt_le_time_approx`). Aquí ε es la infidelidad de un estado de salida concreto, no una infidelidad media de la puerta.

Qué se sabe. Para dos cúbits sin ancillas el resultado es conocido con igualdad: Dür *et al.* [4] resuelven la dinámica de los coeficientes de Schmidt, $P(t) = \sin^2[h_{\max} t + \varphi_0]$, que da un estado de Bell en $\pi/(4h_{\max})$; Vidal, Hammerer y Cirac [5] dan el coste de interacción $C_H(\mathrm{CNOT}) = (\pi/4)(1/h_1)$. La maquinaria en la imagen de interacción para qudits con $\|H_c\| \leq J$ y control local no acotado está en Basyildiz, Jameson y Gong [7] (Sec. II, Ecs. (1)–(7)), donde se aplica a la iSWAP con un criterio de ortogonalidad; el paso «solapamiento con un producto $\leq$ mayor coeficiente de Schmidt» combinado con la forma en $\arccos$ de MT está en Rudnicki [10]. El enunciado para d arbitrario y ancillas con el criterio de Schmidt no se encontró como teorema escrito en las fuentes que leímos; es un corolario breve de [7], [10], y quien lea [7] lo verá como una extensión natural: los autores escriben que «un análisis similar pero posiblemente más complicado puede aplicarse para obtener el límite de velocidad de otras puertas de dos cúbits» (traducción nuestra). Lo que añadimos es el enunciado verificado por máquina. El estado inicial debe ser un producto (ancillas incluidas): con ancillas preentrelazadas el argumento no se aplica [5], [11].

III. Datos y convenios

III-A. Fuentes

Todos los datos son instantáneas públicas distribuidas con Qiskit bajo la licencia Apache 2.0: los backends simulados (*fake backends*) de `qiskit-ibm-runtime` 0.51.0 [19] (`props_*.json`: T_1, T_2, frecuencia, anarmonicidad, errores y duraciones de las puertas por cúbit; `conf_*.json`: las variables hamiltonianas del modelo de Duffing, w_q, δ, `omegad` y j_q, en rad/ns), y las definiciones de pulsos calibrados (`defs_*.json`, 32 backends) de `qiskit-terra` 0.24.1 [20]. Ningún cálculo mezcla los dos paquetes: los análisis que usan formas de pulso (convenio, excitación de pico, resonancia cruzada, Figs. 1–2, duraciones por cúbit) leen solo los `defs` y `conf` de terra 0.24.1, y los barridos leen solo los `conf` y `props` de runtime 0.51.0. Para la serie temporal (Sección VI) descargamos 13 versiones de Qiskit (terra 0.16–0.25 salvo la 0.18.3, que no se descargó; runtime 0.20–0.51), lo que da 101 instantáneas únicas (backend, fecha), de las cuales 56, de 41 backends, son utilizables. Las instantáneas son calibraciones de una fecha dada, no datos en vivo; IBM ha ido retirando el acceso a nivel de pulso y los datos de frecuencia y anarmonicidad [12], lo que convierte las instantáneas con versión fijada en la fuente citable

Tabla I
ENUNCIADOS CERTIFICADOS QUE SE USAN EN ESTE ARTÍCULO (LEAN 4, COMMIT `42f307b`) Y SU ESTADO EN LA LITERATURA.

Teorema de Lean (prefijo `QSL.`)	enunciado	estado
`margolus_levitin`	$\pi \le 2\langle E\rangle\tau$	clásico [2]
`mandelstam_tamm_L1, _weak`	$1 \le D_1\tau \le \Delta E\,\tau$	forma débil de [1]
`zielinski_zych_all`	$\pi^\alpha \le 2M_\alpha\tau^\alpha$, todo $\alpha>0$	enunciado en [3]; allí la desigualdad clave no se demuestra
`Qudit.arccos_le_entangling_time`	$\arccos\lambda \le J\sum\tau_k$	corolario de [7], [10]
`Qudit.pi_div_four_le_entangling_time_fin`	Bell: $J\sum\tau_k \ge \pi/4$, todo d	$d=2$: [4], [5]
`Qudit.entangling_time_tight`	se alcanza con $J\,Z\otimes X$	$d=2$: [4], [5]
`Qudit.pi_div_four_le_entangling_time_local, _shift_local`	lo mismo para $(P\otimes Q)$ Bell (ECR)	corolario
`TwoQubit.entangling_time_lower_bound`	forma de cuerda, constante $\sqrt{2-\sqrt{2}}$	versión anterior, más débil
`Qudit.arccos_le_entangling_time_shift`	$\|H\| \to \|H - c\mathbb{1}\|$	corolario; $d=2$: [4]
`Qudit.pi_div_eight_le_heisenberg_time`	Bell con Heisenberg: $T \ge \pi/8$	$d=2$, sin ancilla: [4]
`Gate.fsAngle_le_time_halfWidth`	ángulo $\le (\Omega_{\max}/2)\,T$, $H(t)$ constante a trozos	estándar (MT desplazada)
`FixedAxis.mandelstam_tamm_integral_eq_solution`	$\int\Delta E = \arccos\|\langle\psi_0\|\psi_T\rangle\|$, eje fijo	caso de igualdad de [1]
`Qudit.pi_div_four_sub_le_entangling_time_approx`	Bell con fidelidad $1-\varepsilon$: $J\sum\tau_k \ge \pi/4 - \arcsin\sqrt{\varepsilon}$	corolario robusto; formalizado aquí
`Gate.two_arccos_sqrt_le_time_approx`	transferencia con fidelidad $1-\varepsilon$: $\Omega_{\max}T \ge 2\arccos\sqrt{\varepsilon}$	dos niveles; ajustada
`Exchange.exchange_norm_ge, _le, ratio_tendsto_one`	$\lambda_d^2/2 \le \kappa_d \le 2(d-1)$; $2\kappa_d/\lambda_d^2 \to 1$	no se encontró en las fuentes leídas
`Exchange.refined_cz_lemma`	$\frac{1}{4}\mathrm{Tr}[(P_A\otimes P_B)H_c^2] \le \frac{97}{32}J^2$, códigos de rango 2, $d=3$	lema de la cota refinada de la CZ

y congelable. Nuestros propios datos muestran la misma tendencia: las instantáneas de los procesadores Heron actuales traen un hamiltoniano vacío (en `conf_torino.json`, `hamiltonian = {'h_latex': ''}`, sin `omegad` ni j_q), de modo que `torino`, `fez`, `marrakesh` y `kingston` no aparecen en nuestros barridos. El diagnóstico cubre, por tanto, solo procesadores anteriores a Heron, sobre todo de las generaciones Falcon y Eagle; el barrido de un cúbit incluye también las instantáneas más antiguas de `armonk`, `yorktown`, `manhattan` y `brooklyn` (`barrido.csv`).

III-B. Modelo

El modelo de IBM es un oscilador de Duffing por transmón, en el sistema que rota a la frecuencia del cúbit y con la aproximación de onda rotante (RWA): $H = (\delta/2)\,n(n-1) + \frac{1}{2}\big(u(t)\,b^\dagger + u(t)^*\,b\big)$, con $u(t) = c\cdot\texttt{omegad}\cdot D(t)$ para una excitación de amplitud compleja $D(t)$ (ambas cuadraturas; $\Omega = |u|$ es la frecuencia de Rabi), y un acoplamiento de intercambio $j_q(b_i^\dagger b_j + b_i b_j^\dagger)$ entre transmones acoplados. El límite de velocidad de una puerta X a plena amplitud $|D|=1$ es entonces $\tau_{\mathrm{QSL}} = \pi/(c\cdot\texttt{omegad})$ (y la mitad para $\sqrt{X}$).

III-C. Fijación del convenio de excitación

El factor c no está documentado en las instantáneas. Lo fijamos antes de calcular ninguna distancia, con la rival H3 especificada de antemano (≪un convenio distinto, factor 2 o 2π≫; `ficha_ideas.toml`). El dato independiente es el propio pulso X calibrado: su ángulo de rotación debe ser π. En los 32 backends con definiciones de pulso, $\texttt{omegad}\cdot|\mathrm{amp}|\cdot\mathrm{area} = 1.148\,\pi$ con $c=1$ y $2.296\,\pi$ con $c=2$ (mediana, con una discretización sencilla del área) (`pulsos_x.py`). Adoptamos $c=1$: los convenios con un factor 2 o 2π quedan excluidos. El residuo ≈ 1.15 tiene una explicación exacta en la normalización del pulso. Con $g(x) = \exp[-(x-N/2)^2/(2\sigma^2)]$, $N = 4\sigma$ y $S = \sum_{n=0}^{N-1} g(n+\frac{1}{2})$, sea $A_{\mathrm{rec}} = dt\,[S - N\,g(-\frac{1}{2})]$ el área de la gaussiana muestreada con el valor del borde restado pero *sin* renormalizar el pico, y $A_Q = dt\,[S - N\,g(-1)]/[1-g(-1)]$ el área de la gaussiana ≪elevada≫ (*lifted*) de Qiskit. Entonces $\texttt{omegad}\cdot|\mathrm{amp}|\cdot A_{\mathrm{rec}} = \pi$ en los 777 cúbits con definiciones de pulso, con $1.2\cdot10^{-7}$ de precisión (`cruces_area_cz.py`); el residuo es A_Q/A_{rec}, que tiende a $1/(1-e^{-2}) = 1.15652$ y reproduce, sin ajustar, tanto la dependencia de la anchura de una discretización sencilla (1.1428, 1.1482, 1.1523 para $\sigma = 24, 40, 80$) como los valores 1.1552–1.1565 del convenio de Qiskit (`identidad_calibracion.py`). La comprobación abarca todos los cúbits. Así, `omegad` es coherente con una excitación cuyo pico es $(1-e^{-2})|\mathrm{amp}|$ en unidades de `omegad`; con la normalización de Qiskit, el modelo rotaría de más en un factor 1.1565. Las instantáneas no dicen qué forma de onda llega al cúbit. La razón a plena amplitud que sigue usa solo `omegad` y no depende de esto; las cifras de excitación de pico sí, y damos ambas lecturas.

La misma comprobación pone de manifiesto una propiedad de los datos: para igual σ, el producto $\texttt{omegad}\cdot\mathrm{amp}$ es idéntico hasta 9 dígitos en 27 backends. Por tanto, `omegad` *no* es una medida independiente; IBM lo deriva de la calibración del pulso π. Cualquier correlación entre la duración de la puerta y `omegad` es, pues, en parte circular (Sección IV).

III-D. Exclusiones y falsador

El falsador especificado de antemano era una razón $\tau_X/\tau_{\mathrm{QSL}} < 1$ en cualquier cúbit, imposible para una X exacta con un convenio correcto (una puerta aproximada con

Tabla II
DISTANCIA DE UN CÚBIT, INSTANTÁNEAS DE IBM (`QISKIT-IBM-RUNTIME` 0.51.0; 41 BACKENDS, 1646 CÚBITS). $\tau_{\mathrm{QSL}} = \pi/\texttt{OMEGAD}$ PARA X (PLENA AMPLITUD DE EXCITACIÓN, $|D| = 1$).

magnitud	mediana	percentiles
$\tau_X/\tau_{\mathrm{QSL}}$ (5–95)	11.30	[7.19, 15.54]
$\tau_{\sqrt{X}}/\tau_{\mathrm{QSL}}(\sqrt{X})$	22.61	—
$\tau_X/(2\pi/\lvert\delta\rvert)$ (5–95)	15.45	[10.90, 18.70]
$\Omega_{\mathrm{peak}}/\lvert\delta\rvert$ (750 cúbits, 10–90)	0.0907	[0.0607, 0.0992]

error de traza e permite bajar hasta $(2/\pi)\arcsin(1-e)$, es decir, 0.991 para $e = 10^{-4}$). Saltó: 254 cúbits resultaron más rápidos que su propio límite. Pertenecen a las instantáneas de `brussels`, `prague` y `strasbourg`, cuyo tiempo de muestreo $dt \geq 1$ ns difiere del de todas las demás instantáneas (0.22 ns) y sugiere valores de relleno; no tenemos documentación de su procedencia. Estos backends se excluyen, igual que los cúbits que notifican anarmonicidad nula; la exclusión se decidió después de que saltara el falsador y así lo notificamos. Controles: un cálculo a mano en `armonk` reproduce el script (razón 2.631), y cambiar la unidad de `omegad` desplaza la mediana exactamente en 2π (`barrido.py`). Una instantánea de la serie temporal (`toronto`, 2021-03-15, duración mediana de dos cúbits 6315 ns, razón $\sim$ 40) es un valor atípico, probablemente una calibración degradada; se mantiene en la Tabla IV, y al eliminarla la mediana de dos cúbits de 2021 pasa de 2.78 a 2.74 y la de un cúbit no cambia en absoluto (`toronto_sensibilidad.py`).

IV. PUERTAS DE UN CÚBIT

IV-A. La distancia

En 41 backends y 1646 cúbits (`barrido.py`, salida `barrido.csv`), la puerta X dura una mediana de $\tau_X/\tau_{\mathrm{QSL}} = 11.30$ veces su límite de velocidad de dos niveles a plena amplitud de excitación ($|D| = 1$, $\tau_{\mathrm{QSL}} = \pi/\texttt{omegad}$), con percentiles 5–95 $[7.19, 15.54]$ y mínimo 2.37 (Tabla II). Los cúbits de un mismo backend comparten duración, de modo que no son independientes: la mediana de las 41 medianas por backend es 11.37, y un bootstrap que remuestrea backends enteros da un intervalo del 95 % de $[11.02, 11.65]$ para la mediana (`mediana_por_backend.py`). IBM no excita a esa amplitud; la Sección IV-C separa la parte de la distancia fijada por la excitación realmente usada de la fijada por el margen de amplitud. La puerta $\sqrt{X}$ tiene la misma duración y la mitad de rotación, de modo que su razón mediana es 22.61. Frente a la escala de tiempo de la fuga, $2\pi/|\delta|$, la puerta X dura una mediana de 15.45 períodos $[10.90, 18.70]$.

IV-B. Hipótesis escritas antes del barrido

Antes de calcular escribimos tres rivales con rangos predichos (`ficha_ideas.toml`): H1, puertas limitadas por la amplitud, a 1–2× el límite; H2, puertas limitadas por la fuga, $\tau_X \propto 1/|\delta|$, razón 2–6, sin correlación con `omegad`; H3, un artefacto del convenio. Resultado: H1 se rechaza frente al límite a plena amplitud (las puertas están a $\approx$ 11×); frente a la excitación de pico realmente usada la razón es $\approx$ 2.16 (Sección IV-C), justo por encima del rango de H1, que no especificaba la excitación; con el pico $(1-e^{-2})|\mathrm{amp}|$ coherente con `omegad` (Sección III) es 1.87, dentro de ese rango, de modo que esta comparación depende de la lectura, mientras que la de plena amplitud no; H2 no tiene respaldo (el R^2 de $\log\tau_X$ sobre $\log(1/|\delta|)$ es 0.087, y las puertas duran $\approx$ 15 períodos de fuga); los convenios con factor 2 y factor 2π de H3 quedan excluidos por la comprobación del pulso π, y el 15 % restante es la normalización de la gaussiana elevada (Sección III). El R^2 sobre $\log(1/\texttt{omegad})$ es 0.692 (control con permutación aleatoria, 0.001), pero como `omegad` se deriva de la amplitud y la anchura del mismo pulso (Sección III), esto es en parte circular y no constituye evidencia física independiente.

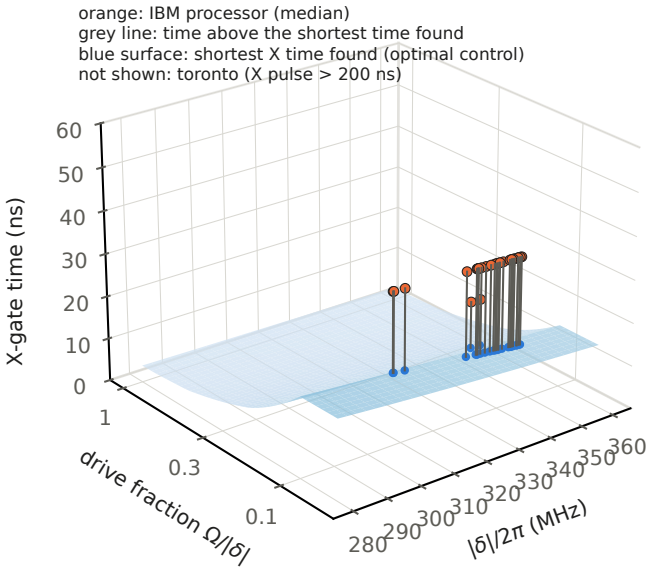


Figura 1. Posición de las puertas de un cúbit de IBM respecto al modelo. Superficie azul: tiempo más corto de la puerta X hallado por control óptimo en un transmón de 4 niveles (Tabla V) en función de la anarmonicidad y de la fracción de excitación $\Omega/|\delta|$. Naranja: un punto por cada procesador de IBM con pulsos calibrados (anarmonicidad mediana, fracción de excitación mediana $\Omega_{\mathrm{peak}}/|\delta|$, duración de X); la línea gris es el tiempo por encima del tiempo más corto hallado con la misma fracción de excitación. `toronto` (pulso X de 2560 muestras) no se muestra, pero está incluido en las medianas. La superficie para $r \geq 0.8$ usa valores de 4 niveles sin converger. Sección VII. Versión interactiva.

IV-C. Qué fija la duración

Escribiendo $\tau_X/\tau_{\mathrm{QSL}} = \mathrm{duration}\cdot dt\cdot \texttt{omegad}/\pi$, la distancia se factoriza en ≈ 2.16—la duración sobre A_{rec}, es decir, el factor de forma del pulso 1.87 (una gaussiana de 4σ con el borde eliminado frente a un pulso cuadrado del mismo pico) multiplicado por la normalización $1/(1-e^{-2})$ de la Sección III—por $1/\mathrm{amp} \approx 5$. Como $\texttt{omegad}\cdot|\mathrm{amp}|\cdot A_{\mathrm{rec}} = \pi$, la razón es exactamente $\tau_X/\tau_{\mathrm{QSL}} = \mathrm{duration}\cdot dt/(|\mathrm{amp}|A_{\mathrm{rec}}) \approx 2.16/|\mathrm{amp}|$: con una envolvente casi fija, la dispersión de la razón es la dispersión de las amplitudes calibradas (IBM calibra el pulso π con $\mathrm{amp} \approx 0.2$: una reserva de amplitud). Ni el límite de velocidad ni la anarmonicidad

fijan la duración; la fijan decisiones de ingeniería: una duración fijada en muestras por backend y una amplitud baja.

La frecuencia de Rabi de pico calibrada se sitúa en una fracción casi fija de la anarmonicidad: en 750 cúbits, $\Omega_{\text{peak}}/|\delta|$ tiene mediana 0.0907 y percentiles 10–90 $[0.0607, 0.0992]$ (`cruce_formulas.py`), es decir, un tope cercano a 0.1, tomando el pico como $\texttt{omegad}\,|\text{amp}|$; con el pico $(1 - e^{-2})\,\texttt{omegad}\,|\text{amp}|$ coherente con `omegad` (Sección III), la mediana es 0.078. Lo interpretamos como una regla de diseño de IBM, no como un límite físico.

La cifra principal y sus denominadores. La mediana 11.3 se mide frente a $\pi/\Omega_{\text{máx}}$ con $\Omega_{\text{máx}} = \texttt{omegad}$, la excitación a plena amplitud $|D| = 1$. La excitación de pico calibrada es $\Omega_{\text{peak}} \approx 0.09|\delta|$; el factor ≈ 5 entre esa excitación y la plena amplitud es un margen elegido por diseño y, con la excitación realmente usada, la distancia es el factor de forma 1.87 si el pico es $(1 - e^{-2})\,\texttt{omegad}\,|\text{amp}|$, o ≈ 2.16 si es $\texttt{omegad}\,|\text{amp}|$ (Sección III). El control óptimo sobre el propio modelo de IBM (Sección VII, Tabla V) acota la ganancia con la misma excitación de pico: como $T \geq 2\arcsin(1-e)/\Omega_{\text{peak}}$, una puerta con $T\Omega_{\text{peak}}/\pi = R_{\text{peak}}$ puede acortarse como máximo en un factor $R_{\text{peak}}/0.991$, es decir, 2.18 con el pico nominal o 1.89 con el pico con el borde restado (con el tope algo mayor $r = 0.1$, el pulso más rápido hallado, ≈ 16 ns frente a 35.6 ns, da 2.2); y, dentro de la amplitud máxima, una puerta mediana de $11.3\,\tau_{\text{QSL}}$ frente a un mínimo comprendido entre $0.99\,\tau_{\text{QSL}}$ (cota) y $1.12\,\tau_{\text{QSL}}$ (hallado en la mediana $r_{\text{full}} = 0.351$, Sección VII), es decir, unas 10–11 veces; para el ejemplo de Falcon (35.6 ns) con esa amplitud, 7.4–8.3 veces. Una puerta de ≈ 3.4 ns necesita aproximadamente el triple de esa amplitud. En resumen: IBM excita a aproximadamente una décima parte de la anarmonicidad; con esa excitación sus pulsos duran unas 2 veces el límite del pulso cuadrado con esa excitación y pueden acortarse como máximo en un factor 2.18 (pico nominal) o 1.89 (pico con el borde restado) con la misma excitación de pico; dentro de la amplitud máxima, el modelo admite puertas unas 10 veces más rápidas que la mediana. La cifra 11.3 no debe leerse como «las puertas son 11 veces más lentas de lo posible»; esas $\approx 10\times$ son una predicción del modelo (Sección IX).

Duraciones por cúbit. Dado que todos los cúbits de un backend comparten una duración, cabe preguntarse cuánto se ganaría dando a cada cúbit la duración más corta compatible con ese tope (fracción de excitación 0.099, el percentil 90 observado), manteniendo la forma del pulso (`mejora_por_cubit.py`, 750 cúbits en 31 backends). La ganancia mediana por cúbit es solo $\times 1.09$ ($\times 1.07$ si una capa espera a su cúbit más lento): el tope limita a casi todos los cúbits por igual. El backend `cairo` es un experimento natural: su duración común de X es 21.3 ns, cuando el tope exigiría una mediana de 31.6 ns, es decir, funciona con una fracción de excitación cercana a 0.15, y funciona.

V. Puertas de dos cúbits

V-A. Pares

De las instantáneas extraemos cada par acoplado que tiene un acoplamiento j_q en las variables hamiltonianas y una puerta de dos cúbits calibrada (`pares.py`): 1758 pares en 43 backends (1019 ECR, 739 CX). El acoplamiento mediano es $j_q = 0.01268$ rad/ns ($g/2\pi \approx 2.0$ MHz), la desintonía mediana 115 MHz ($\approx 60\,j_q$) y la duración mediana de la puerta 548 ns (percentiles 5–95 $[277, 698]$ ns).

V-B. Qué cota

En el subespacio de cúbits, el acoplamiento de IBM es $j_q(\sigma_i^+\sigma_j^- + \text{h.c.}) = (j_q/2)(XX+YY)$, de norma de operador j_q. Se aplican dos cotas, que responden a preguntas distintas.

Cota de la literatura para la puerta. Con control local no acotado, sin fuga y con un acoplamiento XY, el tiempo mínimo de una puerta de clase CNOT (CNOT, CZ, ECR) es $\pi/(2j_q)$. Esto se sigue de Howard *et al.* [9], Apéndice C ($\ll T_{\text{mín}} = \pi/(4g)$ se cumple para H_0, H_0^{XY} y $H_0^{XXZ} \gg$, con $g_H = j_q/2$ en su normalización; traducción nuestra) y de la teoría de mayorización de Vidal–Hammerer–Cirac [5]. La desintonía es un término local absorbido por el control local no acotado, y las excitaciones acotadas son un subconjunto de las no acotadas, de modo que, dentro del subespacio de cúbits, la duración real no puede batirla [inferencia nuestra, no enunciada así en las fuentes].

Nuestra cota certificada para la preparación de estados. El teorema de Lean de la Sección II acota el tiempo de *crear* un estado de Bell a partir de un estado producto: $\pi/(4J)$, alcanzable. Una CNOT completa con un acoplamiento XY necesita el doble de eso, y por ello la cota de la literatura es la más fuerte para las puertas. La nuestra es la verificada por máquina, y sobrevive a niveles extra del transmón: al incluir $|2\rangle$ crece la norma del término de intercambio ($\|a^\dagger b + ab^\dagger\| = 1, 2, 3.4641$ para $d = 2, 3, 4$), y la cota de la CNOT pasa a ser $\pi/(4J)$ con esa J mayor. Con niveles de fuga permitidos, la única constante rigurosa de la literatura es la de la iSWAP [7]; para CNOT/ECR con $|2\rangle$ no se encontró ninguna constante en las fuentes leídas. La nuestra, $\pi/(8j_q)$ para $d = 3$, no es ajustada; la Sección VII la afina hasta $0.4511/j_q$ y, en la versión 3, hasta $0.4632/j_q$ para la CZ.

V-C. Distancias

La Tabla III da ambas razones. Frente a la cota de la literatura $\pi/(2j_q)$, la mediana de las razones por par es 4.22 (la razón entre la duración mediana y la cota mediana sería 4.4). Frente a nuestra constante de cuerda certificada $\sqrt{2-\sqrt{2}}/j_q$, la razón mediana es 8.7; la constante precisa de Lean, $\pi/4$, la reduce un $2.6\,\%$, hasta 8.4, y como $\pi/(4j_q)$ es exactamente la mitad de $\pi/(2j_q)$, la razón certificada es exactamente el doble de la razón de la literatura. Ambas son correctas; acotan tareas distintas. Las dos suponen $\|H_{\text{int}}\| = j_q$, es decir, el subespacio de cúbits. Con el segundo nivel del transmón la norma crece hasta $2j_q$, la cota certificada del tiempo se reduce a la mitad, $\pi/(8j_q)$, y la razón certificada se duplica hasta ≈ 16.9: la cota se vuelve más débil, lo que no dice nada sobre cuánto de ese margen es alcanzable.

Controles numéricos de la cota certificada (`control_dos_cubits.py`): la desigualdad de Duhamel tiene 0 violaciones en $20\,000$ pares aleatorios, con razón máxima 0.99998 (la constante 1 es ajustada), y la cota tiene 0 violaciones en 3000 evoluciones con control local aleatorio.

Tabla III
DISTANCIA DE DOS CÚBITS (1758 PARES, 43 BACKENDS; 1019 ECR, 739 CX). SUBESPACIO DE CÚBITS, $\|H_{\text{int}}\| = j_q$.

cota	fuente	razón mediana
puerta de clase CNOT, $\pi/(2j_q)$	[9], [5] (no en Lean)	4.22
preparación de Bell, $\sqrt{2-\sqrt{2}}/j_q$	Lean, forma de cuerda	8.7
preparación de Bell, $\pi/(4j_q)$	Lean, precisa	2× fila 1

Tabla IV
DISTANCIAS MEDIANAS POR AÑO (56 INSTANTÁNEAS UTILIZABLES, 41 BACKENDS). RAZÓN DE DOS CÚBITS FRENTE A $\pi/(2j_q)$.

	2021	2022	2023	2024	2025
τ_X/τ_{QSL}	11.28	11.32	11.21	11.10	11.87
$\tau_{2q}/(\pi/2j_q)$	2.78	2.64	4.32	3.89	4.26
instantáneas	27	4	2	16	7

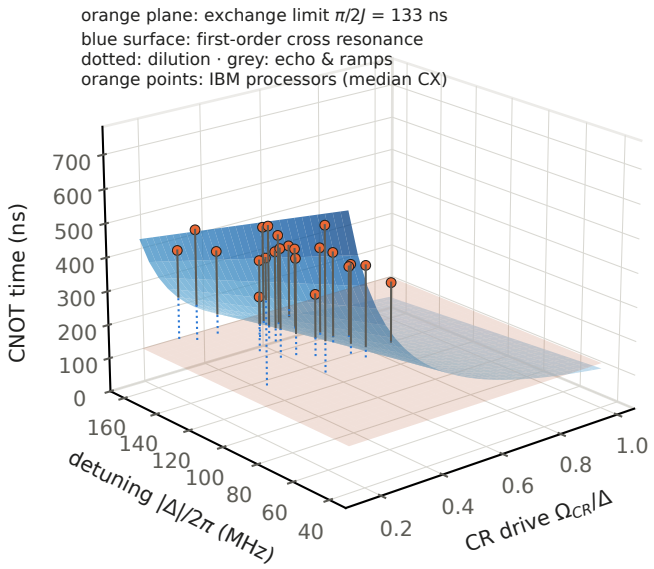


Figura 2. Dos distancias en la puerta de dos cúbits. Plano naranja: límite de velocidad de intercambio $\pi/(2J) = 133\,\text{ns}$ con el acoplamiento mediano de los 29 procesadores con datos de pulso ($J = 0.0118\,\text{rad/ns}$; la mediana sobre los 1758 pares de la Sección V es 0.01268). Superficie azul: tiempo de la CNOT permitido por la resonancia cruzada a primer orden, $t = (\pi/2)/\nu_{ZX}$, en función de la fracción de excitación Ω_{CR}/Δ y de la desintonía. Puntos naranjas: uno por procesador de IBM con pulsos CX calibrados (fracción de excitación, desintonía y duración de la CX medianas). Punteado: dilución por el mecanismo de resonancia cruzada (del plano a la superficie); gris: el resto (de la superficie al punto), debido a los pulsos de eco y las rampas y al error del modelo de primer orden. J y anarmonicidad medianas. Versión interactiva.

V-D. Resonancia cruzada frente a su fórmula de primer orden

La CX de IBM se construye con pulsos de resonancia cruzada (CR) con eco. A primer orden, la excitación CR de amplitud Ω sobre el control, con desintonía Δ, produce una tasa ZX $\nu_{ZX} = -(J\Omega/\Delta)\,\delta_c/(\delta_c + \Delta)$ (el coeficiente de $ZX/2$ a primer orden en J y Ω, [18, Ec. (4.26)], con $\Delta = \omega_c - \omega_t$ y $H = (\nu_{ZX}/2)\,ZX$), y una CNOT necesita $\theta_{ZX} = \nu_{ZX} t_{\text{CR}} = \pi/2$. En 1212 puertas CX calibradas de 29 backends (`cruce_formulas.py`, definiciones de pulso de `qiskit-terra` 0.24.1), la mediana de $\theta/(\pi/2)$ es 1.109, con percentiles 10–90 $[0.870, 1.472]$, y el 59 % en $[0.8, 1.2]$. La mediana queda un 11 % por encima del objetivo, con una dispersión amplia. La excitación calibrada se sitúa en una fracción casi fija de la desintonía: $|\Omega_{\text{CR}}/\Delta|$ tiene mediana 0.451.

Las dos distancias comparten un patrón: el control funciona a una fracción fija de una separación de energía que no debe excitar— $\Omega_{\text{peak}} \approx 0.09|\delta|$ para un cúbit, $\Omega_{\text{CR}} \approx 0.45\Delta$ para dos. Salvedades: la fórmula es de primer orden (sin ZZ, IX ni diafonía clásica), las áreas de las rampas usan el convenio de gaussiana cuadrada «elevada» de Qiskit, y los ángulos no se han comprobado con una simulación completa. Las excitaciones calibradas quedan fuera del rango de validez declarado del desarrollo perturbativo ($\Omega/\Delta \ll 1$; el 53 % de las puertas tiene $\Omega/2\pi > 50\,\text{MHz}$). Con el término de tercer orden de [18, Ec. (4.25)], integrado sobre la forma real del pulso, la mediana baja a 0.898 ($[0.659, 1.105]$); una diagonalización por bloques numérica (el método de mínima acción de [18, App. A1], con cuatro niveles por transmón) da 0.967 ($[0.795, 1.159]$, 81 % en $[0.8, 1.2]$) (`fuentes/cruce_mg2020.py`). Cambiar el signo de Δ aleja la mediana de 1 (0.664), como debe hacer un control. Hay un convenio sin resolver: en los hamiltonianos de los backends de Qiskit, el canal de control del par (c, t) se pondera con la intensidad de excitación del *blanco* ($\texttt{omegad}_t$), mientras que nosotros usamos la del control; con la primera, la mediana de primer orden es 1.089.

VI. SERIE TEMPORAL 2021–2025

Las instantáneas de las distintas versiones de Qiskit (Sección III; `serie_temporal.py`, `serie_porque.py`, `duracion_error.py`) dan la evolución de ambas distancias (Tabla IV).

Un cúbit: congelada. La razón respecto al límite a plena amplitud se mantiene en $\approx$ 11 de 2021 a 2025: una constante de diseño, coherente con la lectura de ingeniería de la Sección IV-C.

Dos cúbits: la duración, no el acoplamiento archivado. La razón creció de 2.78 (2021) a 4.26 (2025). El acoplamiento archivado no cambió: $g/2\pi \approx 1.9$–$2.1\,\text{MHz}$ en todas las familias de procesadores, y dentro de un procesador j_q es *idéntico* en todas las fechas: un valor del modelo arrastrado, no vuelto a medir. Lo que cambia es la duración: las puertas ECR de Eagle (mediana 562 ns) frente a las CX de Falcon ($\approx$ 377 ns), y las recalibraciones alargan las puertas y nunca las acortan en los ejemplos examinados (`bogota` 366 → 544 ns, `perth` 380 → 491 ns, `lagos` 299 → 452 ns). Las medianas de 2022 y 2023 descansan en 4 y 2 instantáneas respectivamente (Tabla IV; fuente: `serie_temporal.py`). La tendencia describe las instantáneas de la serie, que son todas anteriores a Heron: refleja la transición de las puertas CX de Falcon a las ECR de Eagle, no a toda la flota. La generación Heron actual, con puertas CZ de $\approx$ 68–70 ns (68 ns de mediana en nuestra instantánea de `torino`; 70 ns medidos en `ibm_torino` en [12]), no está en la serie porque sus instantáneas no incluyen hamiltoniano (Sección III).

Sin indicios de que alargar reduzca el error. En las 80 instantáneas con duraciones y errores de dos cúbits, la corre-

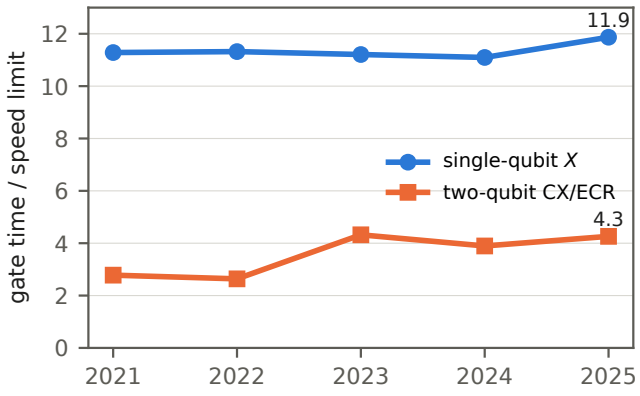


Figura 3. Mediana anual de las medianas de las instantáneas: razón de un cúbit congelada cerca de 11, razón de dos cúbits creciendo con la duración de la puerta. Versión interactiva, desglosada por puerta o tamaño del procesador y seguida procesador a procesador.

lación de Spearman entre la duración mediana de dos cúbits y el error mediano de puerta es $+0.13$ ($p = 0.23$), lo que no excluye un beneficio. Para un mismo par alargado entre dos fechas (71 casos), el error aumentó (cambio mediano en log del error de $+0.21$; solo en el 31 % disminuyó); para los pares acortados (40 casos) disminuyó. Estas comparaciones son observacionales: en las mismas fechas ocurren otros cambios de calibración y deriva.

Una lección metodológica. Después nos preguntamos si los pares alargados tenían peores cúbits. Agregando todas las fechas, el T_1 de los pares alargados cayó más que el de los pares sin cambios (Mann–Whitney $p = 0.0017$; `degradacion.py`). Con un control estratificado (mismo backend, mismas fechas; 18 estratos, 84 pares alargados), el efecto desapareció (Wilcoxon $p = 0.90$ para T_1, $p = 0.99$ para T_2); un efecto agregado de desplazamiento de frecuencia ($p = 4 \cdot 10^{-12}$) desapareció igualmente (`frecuencia_degradados.py`). Los efectos agregados son coherentes con una confusión por época: los alargamientos se concentran en backends y períodos en los que cayó el T_1 de todo el chip. Retiramos la lectura de que los pares alargados tuvieran cúbits degradados: tras controlar por backend y fecha, los datos no respaldan una degradación específica de los pares. Esto no demuestra qué es lo que sí provoca el alargamiento. Todo efecto entre fechas en instantáneas de calibración debería contrastarse estratificando por backend y fecha antes de interpretarlo.

VII. Hasta dónde llega el modelo

Métricas y controles. En los tres problemas el error es $1-F$ con $F = |\mathrm{Tr}(V^\dagger PUP)|/m$, donde V es el objetivo en el subespacio de cúbits de dimensión m, P el proyector sobre él y U el propagador completo; F ignora la fase global, y la fuga la reduce porque entonces PUP es subunitario. La fuga que se notifica es $1-\|PUP\|_F^2/m$, el promedio sobre las entradas computacionales. Los conjuntos de control difieren: para X, una excitación dipolar compleja $|u| \le r|\delta|$ más rotaciones Z virtuales libres antes y después; para la CNOT, una excitación de resonancia cruzada acotada sobre el control, una excitación débil sobre el blanco y rotaciones de un cúbit libres antes y después; para la CZ, generadores hermíticos locales arbitrarios en cada transmón, acotados por $a_{\max}$ durante la puerta, más unitarios locales instantáneos arbitrarios antes y después. Este último conjunto es mucho más amplio que una excitación de microondas sobre un transmón de Duffing.

VII-A. Un cúbit

Ejecutamos control óptimo (`grape_1q.py`) sobre un transmón de Duffing de 4 niveles en unidades $|\delta| = 1$, con una excitación compleja constante a trozos acotada por $|\Omega| \le r|\delta|$, y buscamos, en una rejilla de tiempos, el tiempo más corto con el que se halla una puerta X con error $< 10^{-4}$ incluyendo la fuga. El control de dos niveles devuelve exactamente $T = \pi/\Omega_{\max}$. Los resultados (Tabla V) siguen

$$T_{\text{found}} \approx \max\!\big(\pi/\Omega_{\max},\ \sim 1.1 \cdot 2\pi/|\delta|\big), \qquad (1)$$

una rama de límite de velocidad para $r \lesssim 0.3$ y una rama dominada por la fuga para $r \gtrsim 0.8$. La ecuación (1) es un ajuste empírico a una rejilla gruesa, no un teorema; se queda corta en los valores hallados para $r = 0.3$–0.5 en un 13–16 %, donde ninguna rama domina. Las entradas son tiempos factibles hallados, es decir, cotas superiores del mínimo verdadero: un tope mayor admite todos los pulsos de uno menor, de modo que el mínimo verdadero no puede crecer con r, y el hecho de que el valor en $r = 1.5$ supere al de $r = 1.0$ muestra que la búsqueda es local. Una cota inferior vale para cualquier número de niveles. Con $H(t) = H_{\text{diag}}(t) + \frac{1}{2}(u\,b^\dagger + u^* b)$, $|u| \le \Omega_{\max}$, y $p_0 = |a_0|^2$ la población de $|0\rangle$, la única salida de $|0\rangle$ pasa por $|1\rangle$, de modo que $|\dot{p}_0| \le |u|\,|a_0||a_1| \le |u|\sqrt{p_0(1-p_0)}$ y el ángulo $\theta = \arccos\sqrt{p_0}$ cumple $|\dot{\theta}| \le |u|/2$. Una puerta X lleva θ de 0 a $\pi/2$, de donde $T \ge \pi/\Omega_{\max}$ para cualquier truncamiento; con una fidelidad de transferencia $|\langle 1|\psi_T\rangle|^2 \ge 1-\varepsilon$, $T \ge 2\arccos\sqrt{\varepsilon}/\Omega_{\max}$. (Esta demostración breve es nuestra y no está formalizada; el caso de dos niveles es `QSL.Gate.two_arccos_sqrt_le_time_approx`.) En la métrica de la traza de la Tabla V, el mismo argumento acota $|U_{10}|, |U_{01}| \le \sin(\Omega_{\max} T/2)$ para $T \le \pi/\Omega_{\max}$, de modo que un error e exige $T \ge 2\arcsin(1-e)/\Omega_{\max}$; para $r \le 0.2$ los tiempos hallados quedan un 6 % por encima ($e = 10^{-4}$), así que ahí el mínimo se conoce con un 6 % de precisión; con el tope $\Omega_{\max} = 0.1|\delta|$ ($|\delta| = 2.07$ rad/ns), algo por encima de la excitación de pico calibrada y, por tanto, no la comparación a igual pico de la Sección IV-C, los 35.6 ns archivados quedan entre 2.2 y 2.4 veces el mínimo verdadero (cota 15.0 ns para esa tolerancia, pulso hallado 15.9 ns).

Para el $|\delta| \approx 2.07$ rad/ns típico de IBM, el pulso más rápido hallado con el propio tope de IBM, $r = 0.1$, dura ≈ 16 ns, frente a los 35.6 ns de las puertas de un cúbit de Falcon (por ejemplo, `jakarta`): un factor ≈ 2.2 con ese tope, que está algo por encima de la excitación de pico calibrada (mediana 0.091). Con $r = 1$, la búsqueda de 4 niveles halla $T = 6.9/|\delta|$ (3.3 ns), pero el truncamiento importa con esta excitación: el pulso de 4 niveles en $T = 7.0/|\delta|$ mantiene $1 - F = 7 \cdot 10^{-9}$ en 4 niveles pero se degrada a 5.5–$7.2 \cdot 10^{-4}$ con 5 a 12, y la cota de Duhamel para la distancia a un modelo mayor, $\eta_4 = \int |u|\,\|\langle 3|UP\|\,dt = 0.55$, no lo

Tabla V
TIEMPO MÁS CORTO DE LA PUERTA X HALLADO POR CONTROL ÓPTIMO (UNA COTA SUPERIOR DEL MÍNIMO), TRANSMÓN DE 4 NIVELES, ERROR $< 10^{-4}$ CON FUGA, UNIDADES $|\delta| = 1$ (`GRAPE_1Q.PY`).

$r = \Omega_{\max}/\lvert\delta\rvert$	T_{found}	$T_{\text{found}}/(\pi/\Omega_{\max})$
0.1	33.0	1.05
0.2	16.5	1.05
0.3	12.0	1.15
0.5	8.2	1.30
0.8	7.1	—
1.0	6.9	—
1.5	7.3	—

certifica. Un pulso optimizado con 6 niveles en el mismo tiempo alcanza $1 - F = 4.0 \cdot 10^{-6}$ y $3.6 \cdot 10^{-6}$ con 8 y 12 niveles (`truncacion_1q.py`), de modo que una puerta de $\approx 3.4\,\text{ns}$ ($T = 7.0/|\delta|$), más de diez veces más corta que la de IBM, sobrevive en el modelo convergido; es un testigo numérico en un modelo idealizado, no un suelo físico. Las entradas de la tabla para $r \geq 0.8$ son valores de 4 niveles y no han convergido en el número de niveles. Con el tope de IBM, el pulso de 4 niveles no se ve afectado por más niveles ($\eta_4 = 0.01$). La fracción de excitación $r = 1$ no está disponible en las instantáneas analizadas: la plena amplitud $|D| = 1$ corresponde a $r_{\text{full}} = \text{omegad}/|\delta|$, de mediana 0.351 (percentiles 5–95 $[0.24, 0.61]$; `tercera_revision.py`). Con $r = 0.351$, una búsqueda de 6 niveles halla una X en $T = 10.0/|\delta| = 4.8\,\text{ns}$ con $1 - F = 2.8 \cdot 10^{-8}$, sin cambios con 12 niveles, mientras que la cota anterior da $T \geq 8.87/|\delta| = 4.3\,\text{ns}$; así, dentro del presupuesto de amplitud del dispositivo mediano, una puerta de Falcon de 35.6 ns es 7.4 veces la puerta más rápida hallada y como máximo 8.3 veces la cota, es decir, 7.4–8.3 veces el mínimo del modelo, y la puerta mediana ($11.3\,\tau_{\text{QSL}}$, con $\tau_{\text{QSL}} = 8.95/|\delta|$ en $r = 0.351$) es 10–11 veces. Como punto de comparación independiente, el control óptimo ha demostrado [15] un pulso de un cúbit de 4.16 ns en un transmón superconductor, con fidelidad del 99.76 % y 0.044 % de fuga; sus pulsos elementales son $\pm X/2$ y $\pm Y/2$, caracterizados con protocolos basados en Clifford, una tarea distinta de nuestra puerta X simulada, así que da contexto, no validación. Límites: la rejilla de tiempos es gruesa, la búsqueda es local y el modelo no incluye ruido ni distorsión de línea.

VII-B. Dos cúbits

Resonancia cruzada. Optimizamos una CNOT en dos transmones de 3 niveles con una excitación de resonancia cruzada acotada por $|\Omega_{\text{CR}}| \leq r\Delta$ con los parámetros medianos de IBM ($J/\Delta = 0.0176$, $\delta/\Delta = -2.7$, 10 segmentos; `grape_cr.py`). En unidades del tiempo de intercambio $\pi/(2J)$, los tiempos factibles más cortos hallados (error $< 10^{-3}$, cotas superiores del mínimo) son 3.27 ($r = 0.25$), 1.82 ($r = 0.45$, la fracción calibrada de IBM) y 1.50 ($r = 0.7$). Como un tope mayor admite todos los pulsos de uno menor, 1.50 es también factible para todo $r \geq 0.7$; las búsquedas independientes con $r = 1.0$ y 1.5 devolvieron tiempos más largos, un fallo de la búsqueda local, que confirmamos reexpresando el pulso de $r = 0.7$ bajo los topes mayores (mismo error) y continuando desde él hacia tiempos más cortos, lo que no alcanzó 10^{-3} hasta 1.2 (`grape_cr_continuacion.py`). Las búsquedas usan rejillas de tiempo gruesas y pocos inicios aleatorios; una repetición con $r = 0.7$, $T = 1.50$ llegó solo a $1.2 \cdot 10^{-3}$. Lo que respaldan los datos es que, con la fracción de IBM, la CNOT más rápida hallada es ≈ 1.2 veces más lenta que con $r = 0.7$; no establecen un óptimo en r.

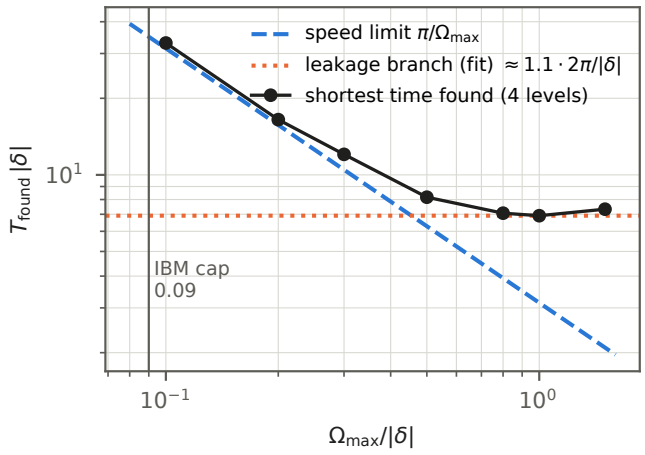


Figura 4. Tiempo más corto de la puerta X hallado por control óptimo en un transmón de 4 niveles (error $< 10^{-4}$, fuga incluida) frente a la cota de excitación: rama de límite de velocidad $\pi/\Omega_{\max}$ y rama dominada por la fuga $\approx 1.1 \cdot 2\pi/|\delta|$ (ajuste empírico). La línea vertical marca el tope observado en las calibraciones de IBM. Versión interactiva.

Tabla VI
CZ EN EL SUBESPACIO DE CÚBITS DE DOS TRANSMONES DE 3 NIVELES ACOPLADOS POR INTERCAMBIO: MEJOR ERROR $1 - F$ FRENTE AL TIEMPO DE PUERTA T Y A LA COTA DE CADA CONTROL LOCAL $\|A_k\|, \|B_k\| \leq a_{\max}$ (`GRAPE_CZ_TORCH.PY`, `VERIFICAR_CZ.PY`). LÍMITE SOLO CON CÚBITS $\pi/(2J) = 1.571/J$; COTAS INFERIORES $\pi/(8J) = 0.393/J$ (CERTIFICADA) Y $0.4511/J$ (REFINADA, SECCIÓN VII), $0.4632/J$ (DOS COPIAS, VERSIÓN 3); CONSTRUCCIÓN EXPLÍCITA $\pi/(6J) = 0.524/J$, PROTOCOLO CERTIFICADO $0.5200/J$ (VERSIÓN 3). CADA CELDA ES EL MEJOR RESULTADO DE HASTA 12 (SIN TOPE) U 8 (CON TOPE) INICIOS ALEATORIOS; LAS DIFERENCIAS INFERIORES A 10^{-8} ENTRE COLUMNAS SON RUIDO DEL OPTIMIZADOR.

$T\,J$	ninguno	$40J$	$20J$	$10J$
0.40	$1.6 \cdot 10^{-2}$			
0.45	$5.0 \cdot 10^{-3}$	$5.3 \cdot 10^{-3}$	$5.5 \cdot 10^{-3}$	
0.50	$3.7 \cdot 10^{-4}$	$4.2 \cdot 10^{-4}$	$4.5 \cdot 10^{-4}$	$1.3 \cdot 10^{-3}$
0.55	$7 \cdot 10^{-12}$	$8 \cdot 10^{-13}$	$2 \cdot 10^{-11}$	$2 \cdot 10^{-8}$
0.60	$3 \cdot 10^{-10}$			$1 \cdot 10^{-9}$

CZ con el segundo nivel. Dos transmones de 3 niveles con un acoplamiento de intercambio fijo $J(b_1^\dagger b_2 + \text{h.c.})$ y control local rápido (cualesquiera A_k, B_k hermíticos en cada transmón, 8 segmentos constantes a trozos, gradientes exactos; `grape_cz_torch.py`). El objetivo es la CZ en el subespacio de cúbits sin fuga; la acción fuera de él es libre, como en [7]. Cada solución se recalcula de forma independiente en float64 (`verificar_cz.py`). Como control, la búsqueda solo con cúbits reproduce el tiempo conocido $\pi/(2J)$ [9] (una puerta en $\pi/(2J)$, ninguna en $0.89\,\pi/(2J)$). Con el segundo nivel:

Cotas. Escribimos T_* para el tiempo mínimo de una CZ exacta

con control local ideal (no acotado e instantáneo), y $T_*(e)$ para el tiempo mínimo de una CZ con error como máximo e en la métrica de la traza usada en todo el artículo. La CZ lleva $|{+}{+}\rangle$ a un estado maximalmente entrelazado, de modo que el teorema del tiempo de entrelazamiento de la Sección II con $\|H_c\| = 2J$ ($d = 3$) da $T_* \geq \pi/(8J) = 0.393/J$. Para una puerta con error e, añadimos una referencia de dos niveles a cada transmón y partimos del producto (a través de $AA'{:}BB'$) de dos estados locales maximalmente entrelazados: el solapamiento del estado resultante con el producido por la CZ es exactamente $|\mathrm{Tr}(CZ^\dagger PUP)|/4 = 1 - e$, fuga incluida, y el estado de la CZ tiene coeficientes de Schmidt $(1/\sqrt{2}, 1/\sqrt{2})$ a través de ese corte, mientras que las referencias dejan $\|H_c\| = 2J$ sin cambios. La versión con tolerancia del teorema (`QSL.Qudit.pi_div_four_sub_le_entangling_time_approx`, con $\varepsilon = 1 - (1-e)^2$) da entonces $T_*(e) \geq [\pi/4 - \arccos(1-e)]/(2J)$ (esta instanciación con referencias es nuestra, no está formalizada; `tercera_revision.py`). Preparar la única salida $CZ|{+}{+}\rangle$ es una tarea mucho más fácil: las operaciones locales llevan $|{+}{+}\rangle$ a $|12\rangle$, en $\{|12\rangle, |21\rangle\}$ el acoplamiento actúa como $2J\sigma_x$, y las operaciones locales devuelven el resultado al estado de partida, de modo que la cota de preparación de estados se alcanza exactamente: es una cota válida pero débil para la puerta. Una construcción explícita da una cota superior. Escribiendo $H_c = \frac{J}{2}(Q \otimes Q + \Pi \otimes \Pi)$ con $Q = b + b^\dagger$ y $\Pi = i(b^\dagger - b)$, las conjugaciones rápidas de *un* transmón por $W = V_Q\,\mathrm{diag}(1, e^{2\pi i/3}, e^{4\pi i/3})V_Q^\dagger$ (V_Q diagonaliza Q) promedian $\Pi \otimes \Pi$ hasta anularlo y conservan $\frac{J}{2}Q \otimes Q$; codificando cada cúbit en los dos autovectores extremos de Q (autovalores $\pm\sqrt{3}$) se obtiene $\frac{3J}{2}Z \otimes Z$, y por tanto una CZ (salvo fases locales) en un tiempo de interacción $\pi/(6J) = 0.5236/J$, en el límite de operaciones locales arbitrariamente rápidas (`cruces_area_cz.py`). La propia cota de la puerta puede afinarse, porque la puerta debe actuar de forma coherente sobre todas las entradas lógicas (el lema está certificado en Lean como `QSL.Exchange.refined_cz_lemma`, con su caso de igualdad, y comprobado numéricamente en `cota_cz_refinada.py`; el argumento temporal construido sobre él no está formalizado). Sea $L(t)$ la evolución que aplica los mismos controles locales que $U(t)$ pero sin H_c, y $z(t) = U(t)^\dagger L(t)|\Omega_0\rangle$ con $|\Omega_0\rangle$ el estado producto extendido con referencias de más arriba. Entonces $\dot{z} = iU^\dagger H_c L|\Omega_0\rangle$, cuya velocidad de Fubini–Study es la dispersión de H_c en $L(t)|\Omega_0\rangle$; ese estado tiene estado reducido físico $(P_A \otimes P_B)/4$ con P_A, P_B proyectores de rango 2, y para cualesquiera proyectores así $\frac{1}{4}\mathrm{Tr}[(P_A \otimes P_B)H_c^2] \leq \frac{97}{32}J^2$ (con igualdad en $P = \mathbb{1} - |v\rangle\langle v|$, $|v\rangle = \sqrt{7/8}|0\rangle + \sqrt{1/8}|2\rangle$). Como $L(T)|\Omega_0\rangle$ es un producto a través de $AA'{:}BB'$ y el estado de la CZ está a una distancia de Fubini–Study de al menos $\pi/4$ de todo producto, $T_*(e) \geq [\pi/4 - \arccos(1-e)]/(J\sqrt{97/32})$, es decir, $T_* \geq 0.4511/J$ y $T_*(2\cdot 10^{-8}) \geq 0.4510/J$, un 15 % por encima de la cota de la norma. Con control local ideal, $0.4511/J \leq T_* \leq \pi/(6J) = 0.5236/J$ (el valor superior como límite de protocolos finitos); la construcción queda a un 16 % de la cota. Preparar un estado de Bell e implementar la CZ entera tienen, pues, tiempos mínimos distintos en este modelo. *Versión 3: mejoran los dos extremos.* Se aplican dos copias idénticas de un protocolo a $\chi_0 = \psi^-_{A_1A_2} \otimes \psi^-_{B_1B_2}$, los singletes del subespacio de cúbits. Los controles locales conservan los subespacios simétrico y antisimétrico de cada par, y una simetría intercambia las copias, así que el estado se queda en $\wedge^2 \otimes \wedge^2 \oplus \mathrm{Sym}^2 \otimes \mathrm{Sym}^2$; una CZ exacta tiene que llevarlo del primer sector al segundo, a una velocidad como mucho $\|K\|$, con K el bloque de $H_c^{(1)} + H_c^{(2)}$ entre ambos. En aritmética exacta $\|K\|^2 = \frac{23}{2}J^2$ (`cz_v3_norma_K.py`), luego $T_* \geq \pi/(\sqrt{46}\,J) = 0.4632/J$. En el otro sentido, el promedio de 18 conjugados locales de H_c conserva, además de $\frac{J}{2}Q \otimes Q$, un bloque de tres estados $\{|\ell\ell\rangle, |mm\rangle, |hh\rangle\}$ en la base propia de $Q = b + b^\dagger$; con una desintonía local de $|m\rangle$ el bloque vuelve exactamente en $T_2 = 3\pi/\big(2(1+\sqrt{65})J\big) = 0.5200016/J$ y el código sufre una CZ salvo fases locales. Un producto de segundo orden de 64 pasos seguido de una corrección exacta queda certificado por un test de Krawczyk en aritmética de intervalos, $T_* \leq 0.520023/J$ (`cz_v3_certificado_salida.txt`; se rechazan dos controles negativos). Por tanto $0.4632/J \leq T_* \leq 0.5200/J$, entre 0.295 y 0.331 del tiempo con solo cúbits.

Dimensión local mayor. La misma construcción funciona para transmones de d niveles: codificando cada cúbit en los dos autovectores extremos de $Q_d = b + b^\dagger$ (autovalores $\pm\lambda_d$, con $\lambda_d/\sqrt{2}$ el mayor cero del polinomio de Hermite H_d) se obtiene una CZ en un tiempo de interacción $\pi/(2J\lambda_d^2)$, mientras que el teorema del tiempo de entrelazamiento da $\pi/(4J\kappa_d)$ con $\kappa_d = \|b^\dagger \otimes b + b \otimes b^\dagger\|$. La razón entre las dos cotas es $2\kappa_d/\lambda_d^2$: 2, 1.33, 1.27, 1.20, 1.09, 1.05 para $d = 2, 3, 4, 5, 10, 20$, y tiende a 1. Esto está certificado en Lean: $\lambda_d^2/2 \leq \kappa_d \leq 2(d-1)$ (`QSL.Exchange.exchange_norm_ge`, `QSL.Exchange.exchange_norm_le`), $\lambda_d \geq 2(1 - 1/m)\sqrt{d-m}$ para el mayor autovalor (`QSL.Exchange.lamMax_ge`), y $2\kappa_d/\lambda_d^2 \to 1$ (`QSL.Exchange.ratio_tendsto_one`); la velocidad es $O(d^{-2/3})$ por la asintótica del mayor cero de Hermite (DLMF 18.16.17, no formalizada). Con una norma de interacción fija $\|H_c\| = J\kappa_d$, el tiempo de la CZ de la construcción se aproxima, por tanto, a la cota de preparación de Bell: la cota del tiempo de entrelazamiento se vuelve ajustada para la puerta entera cuando $d \to \infty$, con control local ideal. El paso de promediado es un caso del marco de simulación sin sobrecoste de [17]; el código de cuadraturas y el ajuste asintótico no se encontraron en las fuentes que leímos. Ambas cotas pueden calcularse para cualquier d y J en el blueprint.

Soluciones numéricas. Con controles locales de como máximo $10J$ durante la puerta (más unitarios locales instantáneos antes y después), se realiza una CZ con error $\leq 2 \cdot 10^{-8}$ (fuga $\leq 4 \cdot 10^{-8}$) en $T = 0.55/J$, es decir, en 0.35 del tiempo con solo cúbits y un 5 % por encima de la construcción. En $T = 0.45/J$ y $0.50/J$, relajar el tope a $20J$, $40J$ o a ninguno no mejoró las soluciones halladas ($\approx 5 \cdot 10^{-3}$ y $\approx 4 \cdot 10^{-4}$); esto no identifica qué las limita, y no se halló ninguna en $0.50/J$. Para la misma tarea y la misma métrica, $0.4510/J \leq T_*(2 \cdot 10^{-8}) \leq 0.55/J$; la cota muestra además que ningún protocolo alcanza $e \leq 2 \cdot 10^{-8}$ en $T = 0.45/J$ (allí exige $e \geq 1.9 \cdot 10^{-6}$), coherente con el $5 \cdot 10^{-3}$ hallado. Las

soluciones pueblan el segundo nivel: hasta el $60\,\%$ de la población de una entrada computacional abandona el subespacio de cúbits durante la puerta (`poblacion_cz.py`). Cada estado de código de la construcción tiene población $1/3$ en $|2\rangle$, de modo que cada entrada básica codificada tiene $5/9 \approx 56\,\%$ fuera del subespacio de cúbits (las superposiciones van de 0 a $8/9$); junto con los elementos aumentados por $\sqrt{2}$, $\langle 20|H_c|11\rangle$ y $\langle 02|H_c|11\rangle$, identificados para la CNOT [16] y la iSWAP [7], esto sugiere un mecanismo para nuestras soluciones que no hemos aislado. Para la CZ de qutrits, $CZ_3|k,l\rangle = e^{2\pi i kl/3}|k,l\rangle$, con acoplamiento capacitivo y un tope de excitación $40g$, el tiempo de control óptimo que se notifica en [8] es cercano al límite de cúbits. Esa es una puerta distinta: en el subespacio de cúbits es $\mathrm{diag}(1,1,1,e^{2\pi i/3})$, no $\mathrm{diag}(1,1,1,-1)$, y el acoplamiento y los controles difieren, de modo que los dos tiempos no son comparables.

Acoplamiento de Heisenberg y ancillas: una identidad. Para $H = XX + YY + ZZ$ y control local rápido, el menor coeficiente de Schmidt máximo hallado a partir de un estado producto en el tiempo T es $\lambda(T) = \cos(2T)$ con precisión 10^{-13} sin ancillas y 10^{-8} con un cúbit ancilla por lado (`grape_bell_torch.py`), hasta el tiempo de Bell $\pi/8$ [4]. La misma identidad $\lambda(T) = \cos(wT)$, con w la semianchura espectral, vale para los acoplamientos Ising ZZ y XY, normalizados como $H_{\mathrm{XY}} = (XX + YY)/2$ ($w = 1$ en ambos), con y sin ancillas (errores $\le 3\cdot 10^{-7}$). La cota de la norma de la Sección II da la tasa $\|H\| = 3$; la identidad dice que la tasa correcta es la semianchura espectral $(E_{\mathrm{máx}} - E_{\mathrm{mín}})/2 = 2$. Este es un corolario certificado (`QuditEntanglingShift`): como $H - c\mathbb{1}$ difiere de H en $c\mathbb{1} = (c\mathbb{1}) \otimes \mathbb{1}$, que puede absorberse en el control local, $\arccos\lambda \le T\,\|H - c\mathbb{1}\|$ para todo c real; para Heisenberg $\|H + \mathbb{1}\| = 2$ (porque $H + \mathbb{1} = 2\,\mathrm{SWAP}$), de donde $T \ge \pi/8$, que [4] alcanza. La cota certificada da $\lambda(T) \ge \cos(2T)$ para cualquier control, y una trayectoria explícita la alcanza: como $H = 2\,\mathrm{SWAP} - \mathbb{1}$, $e^{-iHT}|01\rangle = e^{iT}[\cos(2T)|01\rangle - i\sin(2T)|10\rangle]$, cuyo mayor coeficiente de Schmidt es $\cos(2T)$ para $T \le \pi/8$. Hasta el tiempo de Bell, el mínimo es por tanto exactamente $\cos(2T)$; los cálculos numéricos son comprobaciones de esto. Las ancillas locales no cambian el espectro del acoplamiento y por ello no pueden reducir esta cota; pasado el tiempo de Bell sí permiten más entrelazamiento del que pueden contener dos cúbits. Para dos cúbits sin ancillas, la tasa coincide con $h_{\mathrm{máx}} = \mu_1 + \mu_2$ de [4].

VIII. Aplicación: una transferencia de estado entre chips

El mismo diagnóstico se aplica a operaciones distintas de las puertas. Sundaresan *et al.* [21] transfieren el estado de un cúbit entre dos procesadores de 120 cúbits por un enlace coaxial de aluminio de $80\,\mathrm{cm}$ (un «L-coupler»), con la excitación relevada a través de un modo estacionario del cable. Publican el acoplamiento máximo cúbit–modo, $g/2\pi = 8$–$9\,\mathrm{MHz}$ (su Fig. 1f), la duración T_g y la fidelidad de cada uno de los cuatro enlaces (su Extended Data Table 2) y los tiempos de coherencia de cúbits y modos del cable (Extended Data Tables 1 y 2). Las formas de onda de los acoplamientos no están publicadas.

Tabla VII
Transferencias entre chips de IBM [21] frente al óptimo de un modo $\pi/(\sqrt{2}\,g)$, para $g/2\pi = 8$ y $9\,\mathrm{MHz}$ (44.2 y 39.3 ns). Error $= 1 - F$ publicado. Coherencia a T_g: modelo de error de IBM (sus ecs. (1)–(2), ocupaciones $\frac{1}{2}$ cúbits, $\frac{1}{2}$ cable; nuestra reproducción). Coherencia a $T_{\mathrm{mín}}$: ecuación maestra de Lindblad del protocolo óptimo con los mismos tiempos de coherencia. Versión interactiva para su propio enlace.

Enlace	T_g (ns)	$T_g/T_{\mathrm{mín}}$	error	coh. a T_g	coh. a $T_{\mathrm{mín}}$
Q240–Q247	312	7.06–7.94	0.71 %	0.63 %	0.13–0.15 %
Q241–Q246	296	6.70–7.53	1.13 %	0.87 %	0.23–0.26 %
Q242–Q245	256	5.79–6.52	1.01 %	0.61 %	0.16–0.18 %
Q243–Q244	312	7.06–7.94	1.14 %	0.94 %	0.22–0.24 %

Modelo. En el subespacio de una excitación, con la aproximación de onda rotante y un modo resonante, el relevo es un problema de tres niveles sobre $|A\rangle$ (primer cúbit), $|C\rangle$ (modo del cable) y $|B\rangle$ (segundo cúbit): $H(t) = g_1(t)\,(|A\rangle\langle C| + \mathrm{h.c.}) + g_2(t)\,(|C\rangle\langle B| + \mathrm{h.c.})$ con $g_i(t)$ complejos, $|g_i(t)| \le g$ y $g = 2\pi \times (g/2\pi)$.

Suelo certificado. Como $\|H(t)\| = (|g_1|^2 + |g_2|^2)^{1/2} \le \sqrt{2}\,g$ y la transferencia $|A\rangle \to |B\rangle$ necesita un ángulo de Fubini–Study $\pi/2$, la cota `QSL.Gate.fsAngle_le_time_halfWidth` de la Sección II (con desplazamiento $c = 0$; vale en cualquier dimensión) da $T \ge \pi/(2\sqrt{2}\,g)$ para acoplamientos constantes a trozos de cualquier fase. Está certificada y no es ajustada.

Óptimo exacto. En este modelo el tiempo mínimo es $\pi/(\sqrt{2}\,g)$, alcanzado con ambos acoplamientos constantes y en su máximo: el caso isótropo del Teorema 1 de Boscain, Chambrion y Charlot [22]. La mitad inferior, $gT \ge \pi/\sqrt{2}$, está verificada por máquina en Isabelle/HOL (`Relay_Minimal_Time.relay_minimal_time`, entrada `Quantum_Speed_Limits` [23]) para las amplitudes $x = |a_A|$, $z = |a_B|$, que cumplen $|\dot{x}|, |\dot{z}| \le g\sqrt{1 - x^2 - z^2}$ salvo en un conjunto numerable de instantes; la prueba usa una función de calibración explícita, y la reducción desde la ecuación de Schrödinger a estas desigualdades (una línea, válida también con varios modos del cable y desintonías cuando g es la norma del vector de acoplamiento de cada extremo) está en el texto, no en Isabelle. También reprodujimos el óptimo numéricamente con controles constantes a trozos, reales y complejos (`tiempo_minimo.py`): ningún control hallado consigue la transferencia completa para $gT < \pi/\sqrt{2}$. Con estos acoplamientos la excitación pasa una cuarta parte del tiempo en el cable ($\int_0^T |c(t)|^2 dt = T/4$). El protocolo secuencial (dos intercambios) tarda π/g.

Distancias. Los cocientes de la Tabla VII son cocientes frente al óptimo del modelo de un modo con los acoplamientos máximos publicados; no muestran que el dispositivo admita una aceleración de ese factor con la misma fidelidad. Las transferencias duran 5.8–7.9 veces el óptimo de un modo (Tabla VII), 4.1–5.6 veces el tiempo secuencial y 11.6–15.9 veces el suelo certificado. Los $126\,\mathrm{ns}$ que los autores dan como objetivo seguirían siendo 2.9–3.2 veces el óptimo (diagnostique su propio enlace: las mismas cifras, una curva de la ecuación maestra frente a la duración y una lectura de qué tiempo de coherencia domina). Según el propio modelo

de error de IBM, la mayor parte del error medido a estas duraciones es coherencia. En el óptimo, con los mismos tiempos de coherencia, el error de coherencia del protocolo óptimo es 0.13–$0.26\,\%$ (ecuación maestra, `lindblad_relevo.py`, contrastada con un integrador independiente, `lindblad_rk4.py`), entre cuatro y seis veces por debajo de los errores medidos. El modelo aditivo de la ec. (2) evaluado con las ocupaciones del protocolo óptimo da menos, 0.09–$0.17\,\%$: es exacto para la relajación pero no para el desfase puro mientras la excitación está repartida entre elementos (`comparar_modelos.py`). Es el error de coherencia de un protocolo admisible, no un suelo: un protocolo más lento puede perder menos (con el cable sin pérdidas y los cúbits con pérdidas, el protocolo secuencial, con el doble de duración, tiene menos error, `falsar_v198.py`), y un suelo exigiría una desigualdad válida para todo control.

Salvedades. (i) El cable tiene muchos modos (rango espectral libre $\approx 150\,\mathrm{MHz}$, $g/\mathrm{FSR} \approx 0.05$–$0.06$ según las cifras de los autores); los protocolos que usan varios modos no están cubiertos por el óptimo de un modo, y para ellos el suelo certificado y la cota de Isabelle $\pi/(\sqrt{2}\,G)$ valen con la norma colectiva de acoplamiento G de cada extremo, que no se publica. (ii) g es el acoplamiento máximo; los cocientes miden la distancia a lo que ese máximo permite, no a las formas de onda usadas. (iii) La fidelidad publicada y el modelo de error son de IBM; las ocupaciones $\frac{1}{2}$–$\frac{1}{2}$ son una hipótesis de IBM, y para los cúbits usamos, como IBM, el tiempo de coherencia más corto de cada par. (iv) La ecuación maestra trata el desfase como markoviano, con la tasa fijada por el T_2 de Ramsey; un ruido de baja frecuencia cambiaría los términos de desfase. El cálculo está en `relevo/cocientes.py`, `relevo/diag_relevo.py` y `relevo/suelo_lindblad.py`, con los datos en `relevo/datos/ibm_2610.29986.toml`.

IX. Qué garantiza y qué no garantiza el certificado

Los objetos certificados son las desigualdades, no las distancias. Los teoremas de la Tabla I están verificados por máquina para todas las entradas que cumplen sus hipótesis. Cada distancia notificada es un cálculo sobre datos del fabricante; su fiabilidad descansa en los controles de la Sección III, no en una demostración.

El modelo es el de IBM, no una medida. Todo límite de velocidad se evalúa en el modelo de Duffing de IBM con la RWA. Si el modelo describe mal un dispositivo, la distancia hereda el error.

`omegad` es derivado. Procede de la calibración del pulso π (Sección III), y un factor $1/(1-e^{-2})$ separa el área con la que se derivó `omegad` del pulso normalizado de Qiskit; cuál de las dos formas de onda llega al cúbit no figura en las instantáneas. Las distancias de un cúbit arrastran esta incertidumbre, y las correlaciones duración–`omegad` son en parte circulares.

Hipótesis del teorema de dos cúbits. El teorema de Lean supone una interacción constante de norma acotada y controles locales constantes a trozos, con un estado inicial producto. Aplicarlo a las puertas de IBM supone que las excitaciones actúan localmente y que el acoplamiento estático es la única interacción (sin diafonía clásica). La cota de un cúbit dependiente del tiempo y el corolario ECR se enuncian en Lean para controles constantes a trozos; un pulso continuo queda cubierto solo como límite de tales controles, lo cual no está formalizado (Sección II). La norma $\|H_{\mathrm{int}}\| = j_q$ vale solo en el subespacio de cúbits, y el propio j_q es un valor del modelo repetido a lo largo de las fechas.

Cotas que no están en Lean. La cota de la literatura para la puerta $\pi/(2j_q)$ que sustenta el 4.22 de la cifra principal, su aplicación a duraciones reales (inferencia nuestra, Sección V), la cota de un cúbit con varios niveles $T \geq \pi/\Omega_{\mathrm{máx}}$ y su versión en la métrica de la traza (demostradas en el texto, Sección VII), la instanciación con referencias, el argumento temporal de la cota refinada de la CZ $0.4511/J$ (su lema de $97/32$ sí está en Lean), la cota con dos copias y el protocolo certificado de la versión 3 (cálculos exactos y con intervalos, no pruebas en Lean), la construcción de la CZ en $d = 3$ y en dimensión d, y la velocidad $O(d^{-2/3})$ no están formalizados (el límite de la razón de cotas sí lo está) (Lean certifica $\pi/(8J)$).

Truncamiento. Los tiempos de un cúbit hallados con 4 niveles para $r \geq 0.8$ no han convergido en el número de niveles (Sección VII); la puerta más rápida convergida, $\approx 3.4\,\mathrm{ns}$, procede de una búsqueda de 6 niveles comprobada hasta 12 niveles.

Modelos efectivos de resonancia cruzada. La comprobación de CR de la Sección V usa hamiltonianos efectivos (primer orden, tercer orden y una diagonalización por bloques numérica estática); ninguno es una simulación dependiente del tiempo de la secuencia de pulsos calibrada con ecos y tonos de cancelación.

Control óptimo grueso. Las Tablas V y VI proceden de rejillas gruesas (pasos de tiempo, 8–10 segmentos constantes a trozos, un número finito de inicios aleatorios), sin ruido; los tiempos notificados son tiempos factibles hallados, es decir, cotas superiores del mínimo, y un tiempo en el que no se halló ninguna puerta no demuestra nada.

Instantáneas, no datos en vivo; sin validación en hardware. Todos los datos son instantáneas con fecha. No hemos ejecutado nada en hardware: IBM ha ido retirando el acceso a nivel de pulso [12], de modo que los tiempos factibles hallados en la Sección VII son predicciones del modelo. Con todo, es factible medir tiempos en hardware real como caja negra: la amplificación del tiempo de puerta [12], que lee las duraciones de las puertas a partir del tiempo de reloj de los trabajos, podría validar las duraciones de las instantáneas usadas aquí. No lo hemos hecho.

Relación con el trabajo previo. El trabajo más cercano, el de Ishida y Hasegawa [12], recorre el sentido inverso: a partir de tiempos de puerta medidos por amplificación en `ibm_torino` infieren escalas de energía mediante ML y MT, y concluyen que las puertas actuales están cerca del QSL. Nosotros tomamos la escala de energía de la calibración (amplitud máxima de excitación, acoplamiento) y preguntamos a qué distancia está la puerta de ella. Las dos responden a preguntas distintas, y las conclusiones deben leerse con sus escalas de energía a la vista. Para una rotación π de un cúbit de eje fijo, su estimador MT es igual a la dispersión de energía

promediada en el tiempo del pulso, de modo que la puerta está en ese límite por construcción; su límite usa la excitación realmente aplicada, mientras que nuestra cifra principal 11.3 usa la excitación a plena amplitud, que IBM no utiliza. Con la excitación realizada, nuestras propias cifras dan una distancia de aproximadamente 2 (Sección IV-C), compatible con su lectura. Su medida es independiente del modelo y se hace en un dispositivo Heron; la nuestra requiere el hamiltoniano del fabricante y cubre solo instantáneas anteriores a Heron. Basilewitsch, Dlaska y Lechner [13] calculan QSL de control óptimo con parámetros de Sycamore; Howard *et al.* [9] ejecutan puertas de dos cúbits en el límite de velocidad en un chip a medida; Basyildiz, Gong y Ashhab [8] comparan un límite teórico de la CZ de cúbits de $\approx$ 46 ns con un experimento de 580 ns. Ese experimento es una CZ de *qutrits*, de modo que el par mezcla un límite de cúbits con una puerta de qutrits. Wu *et al.* [14] contrastan las cotas de Zieliński–Zych en un experimento de transmón y resonador. Ninguno de estos trabajos está verificado por máquina, y ninguno de los que hallamos barre la flota de un fabricante. Nuestro trabajo los complementa: un diagnóstico de toda la flota, con versión fijada y con desigualdades certificadas.

X. Reproducibilidad

Todos los scripts y datos están en el paquete complementario del blueprint, https://karlesmarin.github.io/blueprints/qsl-diagnostics/companion/ (Apache 2.0): `convencion.py` (comprobación de tres niveles del convenio de excitación), `pulsos_x.py` y `identidad_omegad.py`, `identidad_calibracion.py` (convenio a partir de los pulsos π calibrados), `barrido.py` (barrido de un cúbit, `barrido.csv`), `pares.py` (pares de dos cúbits, `pares.csv`), `cruce_formulas.py` (comprobaciones de CR y de Rabi de pico), `serie_temporal.py`, `serie_porque.py`, `duracion_error.py` (serie temporal, `serie.csv`), `degradacion.py` y `frecuencia_degradados.py` (controles estratificados), `mejora_por_cubit.py` (duraciones por cúbit), `mediana_por_backend.py` (mediana ponderada por backend, bootstrap por grupos), `toronto_sensibilidad.py` (sensibilidad a valores atípicos), `control_dos_cubits.py` y `cnot_m3.py` (controles numéricos de las cotas certificadas), `grape_1q.py`, `grape_cr.py` y `grape_cr_continuacion.py` (comprobación de monotonía), `grape_cz_torch.py` con su comprobación independiente `verificar_cz.py`, `grape_bell_torch.py`, `grape_anchura.py`, `poblacion_cz.py` (control óptimo), `fuentes/cruce_mg2020.py` (comprobación de CR de orden superior), `cruces_area_cz.py` (identidad de área del pulso, construcción de la CZ) y `truncacion_1q.py` (comprobación del truncamiento), `tercera_revision.py` (cotas de la métrica de puerta, r_{full}), `cota_cz_refinada.py` (cota refinada de la CZ). Datos: instantáneas de los backends simulados de `qiskit-ibm-runtime` 0.51.0 y `qiskit-terra` 0.24.1 (Apache 2.0), copiadas en `datos/` y `datos_serie/`. Las fuentes de Lean están en https://github.com/karlesmarin/formalizations, commit `42f307b`. Los pulsos calibrados (`qiskit-terra` 0.24.1) están copiados en `datos_pulsos/`; una autocomprobación reconstruye `barrido.csv` dentro del paquete y lo compara con el fichero archivado. Un blueprint complementario, https://karlesmarin.github.io/blueprints/qsl-diagnostics/, asocia cada afirmación de este artículo con su teorema de Lean o su script. Sus laboratorios se ejecutan en el navegador del lector con los valores del propio lector: las Figs. 1–4 redibujadas en vivo; la igualdad de eje fijo en la esfera de Bloch para cualquier envolvente; los suelos certificados de la Sección II para una lista de puertas del propio lector (diagnostique su dispositivo), que dispara el falsador de la Sección III ante cualquier puerta por debajo de su suelo; y las cotas de la CZ de d niveles de la Sección VII. Cada resultado puede descargarse como CSV o compartirse como enlace con sus datos de entrada. Para la Sección VIII (versión 2): `relevo/datos/ibm_2610.29986.toml` (los valores publicados, cada uno con su tabla), `relevo/cocientes.py` (cocientes), `relevo/diag_relevo.py` (modelo de error de IBM), `relevo/lindblad_relevo.py` con su comprobación independiente `relevo/lindblad_rk4.py` (ecuación maestra), `relevo/suelo_lindblad.py`, `relevo/comparar_modelos.py`, `relevo/falsar_v198.py` (modelo aditivo y protocolo más lento), `relevo/tiempo_minimo.py` (óptimo numérico) y `relevo/heya_satd.py`, que reproduce la simulación de Lindblad publicada de una transferencia SATD de IBM [24] ($2.0 \cdot 10^{-3}$ y $6.0 \cdot 10^{-3}$ frente a $2 \cdot 10^{-3}$ y $6.2 \cdot 10^{-3}$) como validación del simulador. Las fuentes de Isabelle de `Quantum_Speed_Limits` están en el mismo paquete.

XI. Conclusión

Con instantáneas públicas de calibración de procesadores IBM anteriores a Heron (sobre todo Falcon y Eagle), las puertas de un cúbit funcionan a una mediana de $11.3\times$ su límite de velocidad de dos niveles a plena amplitud de excitación, una razón que se mantiene a menos de un $5\,\%$ de 11.3 en todos los años de 2021 a 2025. Ese denominador es una amplitud que IBM no usa: excita a aproximadamente una décima parte de la anarmonicidad y, con esa excitación, sus pulsos duran unas 2 veces el límite del pulso cuadrado (el factor de forma 1.87, o 2.16 con la normalización de pico de Qiskit) y pueden acortarse como máximo en un factor 2.18 (pico nominal) o 1.89 (pico con el borde restado) con la misma excitación de pico; el ≈ 5 restante es margen de amplitud, una decisión de diseño. El control óptimo sobre el modelo de IBM halla puertas X de $\approx$ 16 ns con el propio tope de amplitud de IBM y de 4.8 ns con su plena amplitud (donde el mínimo es al menos 4.3 ns): dentro del mismo presupuesto de amplitud, el modelo admite puertas unas 10 veces más rápidas que la puerta mediana (7.4–8.3 veces para una puerta de Falcon de 35.6 ns); $\approx$ 3.4 ns necesita el triple de esa amplitud. Se trata de tiempos factibles en un modelo idealizado, no de suelos físicos. Las puertas de dos cúbits funcionan a una mediana de $4.22\times$ la cota conocida $\pi/(2j_q)$

de las puertas de clase CNOT en el subespacio de cúbits; en las instantáneas, esa razón subió de 2.78 a 4.26 entre 2021 y 2025 a medida que las puertas se alargaban, de forma no monótona y coincidiendo con el paso de la CX de Falcon a la ECR de Eagle, mientras que los acoplamientos archivados no cambiaron. La generación Heron actual (CZ de ≈ 68–70 ns) no está cubierta. Las desigualdades de la Tabla I están verificadas por máquina, incluida una cota del tiempo de entrelazamiento en cualquier dimensión que es nueva solo como ensamblaje certificado de piezas conocidas. Sobre el modelo, el control óptimo halla una CNOT de resonancia cruzada ≈ 1.2 veces más rápida con una fracción de excitación de 0.7 que con la de 0.45 de IBM y, con el segundo nivel del transmón, una CZ (error $2 \cdot 10^{-8}$) en 0.35 del tiempo de intercambio con solo cúbits con controles locales de como máximo $10J$; ambos son tiempos factibles hallados, no mínimos demostrados. Las cuestiones abiertas son el mínimo verdadero entre la cota con dos copias $0.4632/J$ y el protocolo certificado $0.5200/J$ (versión 3) (en transmones de d niveles, la distancia entre la cota de entrelazamiento y la construcción se cierra cuando $d \to \infty$, un límite certificado en Lean), y una cota certificada que una las ramas de límite de velocidad y de fuga de (1), para la cual no tenemos ningún resultado. El mismo diagnóstico aplicado a la transferencia de estado entre chips de IBM (versión 2) la sitúa en 5.8–7.9 veces el tiempo mínimo de un modo $\pi/(\sqrt{2}\,g)$, cuya cota inferior está verificada por máquina en Isabelle, con un error de coherencia a ese tiempo entre cuatro y seis veces por debajo de los errores medidos; es el error de un protocolo, no un suelo.

Conflicto de intereses

El autor declara no tener ningún conflicto de intereses. Este trabajo no ha recibido financiación.

Uso de herramientas de IA

Este trabajo se ha realizado con un asistente de IA. El autor comprobó todos los enunciados, demostraciones y cálculos y asume la plena responsabilidad del contenido.

Referencias

[1] L. Mandelstam and I. Tamm, "The uncertainty relation between energy and time in non-relativistic quantum mechanics," *J. Phys. USSR*, vol. 9, pp. 249–254, 1945.

[2] N. Margolus and L. B. Levitin, "The maximum speed of dynamical evolution," *Physica D*, vol. 120, pp. 188–195, 1998.

[3] B. Zieliński and M. Zych, "A generalization of Margolus–Levitin bound," *Phys. Rev. A*, vol. 74, 034301, 2006. arXiv:quant-ph/0603076.

[4] W. Dür, G. Vidal, J. I. Cirac, N. Linden, and S. Popescu, "Entanglement capabilities of nonlocal Hamiltonians," *Phys. Rev. Lett.*, vol. 87, 137901, 2001. arXiv:quant-ph/0006034.

[5] G. Vidal, K. Hammerer, and J. I. Cirac, "Interaction cost of nonlocal gates," *Phys. Rev. Lett.*, vol. 88, 237902, 2002. arXiv:quant-ph/0112168.

[6] K. Hammerer, G. Vidal, and J. I. Cirac, "Characterization of non-local gates," *Phys. Rev. A*, vol. 66, 062321, 2002. arXiv:quant-ph/0205100.

[7] B. Basyildiz, C. Jameson, and Z. Gong, "Speed limits of two-qubit gates with qudits," arXiv:2312.09218, 2023.

[8] B. Basyildiz, Z. Gong, and S. Ashhab, "Speed limits of two-qutrit gates," arXiv:2510.07742, 2025.

[9] J. Howard, A. Lidiak, C. Jameson, B. Basyildiz, K. Clark, T. Zhao, M. Bal, J. Long, D. P. Pappas, M. Singh, and Z. Gong, "Implementing two-qubit gates at the quantum speed limit," *Phys. Rev. Research*, vol. 5, 043194, 2023. arXiv:2206.07716.

[10] Ł. Rudnicki, "Quantum speed limit helps interpret geometric measure of entanglement," *Phys. Rev. A*, vol. 104, 032417, 2021. arXiv:2107.11877.

[11] S. Bravyi, "Upper bounds on entangling rates of bipartite Hamiltonians," *Phys. Rev. A*, vol. 76, 052319, 2007. arXiv:0704.0964.

[12] N. Ishida and Y. Hasegawa, "Energy inference of black-box quantum computers using quantum speed limit," arXiv:2512.15472, 2025.

[13] D. Basilewitsch, C. Dlaska, and W. Lechner, "Comparing planar quantum computing platforms at the quantum speed limit," *Phys. Rev. Research*, vol. 6, 023026, 2024. arXiv:2304.01756.

[14] Y. Wu, J. Yuan, C. Zhang, Z. Zhu, J. Deng, X. Zhang, P. Zhang, Q. Guo, Z. Wang, J. Huang, C. Song, H. Li, D.-W. Wang, H. Wang, and G. S. Agarwal, "Testing the unified bounds of quantum speed limit," *Phys. Rev. A*, vol. 110, 042215, 2024. arXiv:2403.03579.

[15] M. Werninghaus, D. J. Egger, F. Roy, S. Machnes, F. K. Wilhelm, and S. Filipp, "Leakage reduction in fast superconducting qubit gates via optimal control," *npj Quantum Inf.*, vol. 7, 14, 2021. arXiv:2003.05952.

[16] S. Ashhab, F. Yoshihara, T. Fuse, N. Yamamoto, A. Lupascu, and K. Semba, "Speed limits for two-qubit gates with weakly anharmonic qubits," *Phys. Rev. A*, vol. 105, 042614, 2022.

[17] P. Wocjan, M. Rötteler, D. Janzing, and T. Beth, "Simulating Hamiltonians in quantum networks: Efficient schemes and complexity bounds," *Phys. Rev. A*, vol. 65, 042309, 2002. arXiv:quant-ph/0109088.

[18] E. Magesan and J. M. Gambetta, "Effective Hamiltonian models of the cross-resonance gate," *Phys. Rev. A*, vol. 101, 052308, 2020. arXiv:1804.04073.

[19] Qiskit IBM Runtime, version 0.51.0, `fake_provider` backends, Apache 2.0. https://github.com/Qiskit/qiskit-ibm-runtime.

[20] Qiskit Terra, version 0.24.1, `fake_provider` backends, Apache 2.0. https://github.com/Qiskit/qiskit (package `qiskit-terra` on PyPI).

[21] N. M. Sundaresan *et al.*, "Meter-scale quantum interconnects between large quantum processors," arXiv:2610.29986 (2026).

[22] U. Boscain, T. Chambrion, and G. Charlot, "Nonisotropic 3-level quantum systems: complete solutions for minimum time and minimum energy," *Discrete Contin. Dyn. Syst. Ser. B*, vol. 5, pp. 957–990, 2005; arXiv:quant-ph/0409022.

[23] C. Marín, "Quantum Speed Limits: the Zieliński–Zych Bound and Time–Occupation Bounds for Qubit–Bus–Qubit State Transfer," entrada de Isabelle/HOL (octubre de 2026); fuentes en el paquete complementario.

[24] K. Heya *et al.*, "Randomized benchmarking of a remote CNOT gate via a meter-scale microwave link," *Phys. Rev. Lett.*, vol. 135, art. 200801, 2025; arXiv:2502.15034.

[25] C. Marín, "Formalizations" (Lean 4), https://github.com/karlesmarin/formalizations, commit `42f307b`, 2026. Companion text: C. Marín, "The clock that never ticks: a machine-checked path from the dilogarithm to quantum speed limits in Lean 4," Zenodo, 2026, doi:10.5281/zenodo.20675271.